Παραγωγική Τεχνητή Νοημοσύνη: Generative AI

Κωνσταντίνος Καραμανής
The University of Texas at Austin & Archimedes/Athena RC
constantine@utexas.edu
https://caramanis.github.io/

Αναζήτηση σε Βάση Γνώσεων

Πώς γίνεται η αναζήτηση (search) σε κείμενο;

Αναζήτηση: λέξη σε κείμενο

Πώς γίνεται η αναζήτηση (search) σε κείμενο;

Query term: ‘ποδήλατο’

Κείμενο: Το πρωί που οδηγούσα στο σχολείο είδα έναν άντρα ντυμένο Άγιο Βασίλη, καβάλα σε ένα ποδήλατο, και γέλασα πολύ.

Αναζήτηση: λέξη σε κείμενο

Πώς γίνεται η αναζήτηση (search) σε κείμενο;

Query term: ‘ποδήλατο’

Κείμενο: Το πρωί που οδηγούσα στο σχολείο είδα έναν άντρα ντυμένο Άγιο Βασίλη, καβάλα σε ένα ποδήλατο, και γέλασα πολύ.

Αναζήτηση: λέξη σε κείμενο

Πώς γίνεται η αναζήτηση (search) σε κείμενο;

Query term: ‘ποδήλατο’

Κείμενο: Το πρωί που οδηγούσα στο σχολείο είδα έναν άντρα ντυμένο Άγιο Βασίλη, καβάλα σε ένα ποδήλατο, και γέλασα πολύ.

Αναζήτηση: λέξη σε κείμενο

Πώς γίνεται η αναζήτηση (search) σε κείμενο;

Query term: ‘ποδήλατο’

Κείμενο: Το πρωί που οδηγούσα στο σχολείο είδα έναν άντρα ντυμένο Άγιο Βασίλη, καβάλα σε ένα ποδήλατο, και γέλασα πολύ.

Αναζήτηση: λέξη σε κείμενο

Πώς γίνεται η αναζήτηση (search) σε κείμενο;

Query term: ‘ποδήλατο’

Κείμενο: Το πρωί που οδηγούσα στο σχολείο είδα έναν άντρα ντυμένο Άγιο Βασίλη, καβάλα σε ένα ποδήλατο, και γέλασα πολύ.

Αναζήτηση: λέξη σε κείμενο

Πώς γίνεται η αναζήτηση (search) σε κείμενο;

Query term: ‘ποδήλατο’

Κείμενο: Το πρωί που οδηγούσα στο σχολείο είδα έναν άντρα ντυμένο Άγιο Βασίλη, καβάλα σε ένα ποδήλατο, και γέλασα πολύ.

Αναζήτηση: λέξη σε κείμενο

Πώς γίνεται η αναζήτηση (search) σε κείμενο;

Query term: ‘ποδήλατο’

Κείμενο: Το πρωί που οδηγούσα στο σχολείο είδα έναν άντρα ντυμένο Άγιο Βασίλη, καβάλα σε ένα ποδήλατο, και γέλασα πολύ.

Αναζήτηση: λέξη σε κείμενο

Πώς γίνεται η αναζήτηση (search) σε κείμενο;

CTRL-F

Query term: ‘ποδήλατο’

Κείμενο: Το πρωί που οδηγούσα στο σχολείο είδα έναν άντρα ντυμένο Άγιο Βασίλη, καβάλα σε ένα ποδήλατο, και γέλασα πολύ.

Αναζήτηση: λέξη σε κείμενο

Πώς γίνεται η αναζήτηση (search) σε κείμενο;

CTRL-F

Query term: ‘ποδήλατο’

Κείμενο: Το πρωί που οδηγούσα στο σχολείο είδα έναν άντρα ντυμένο Άγιο Βασίλη, καβάλα σε ένα ποδήλατο, και γέλασα πολύ.

Αναζήτηση: ~~λέξη~~ έννοια σε κείμενο

Πώς γίνεται η αναζήτηση (search) σε κείμενο;

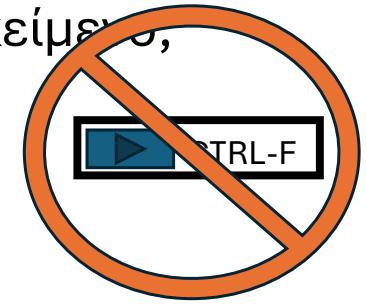

Query term: ‘ποδήλατο’

Κείμενο: Το πρωί που οδηγούσα στο σχολείο είδα έναν άντρα ντυμένο Άγιο Βασίλη, καβάλα σε ένα **δίτροχο**, και γέλασα πολύ.

Αναζήτηση: ~~λέξη~~ έννοια σε κείμενο

Πώς γίνεται η αναζήτηση (search) σε κείμενο;

Query term: ‘ποδήλατο’

Κείμενο: Το πρωί που οδηγούσα στο σχολείο, είδα ένα γέρο ντυμένο Άγιο Βασίλη, καβάλα σε ένα **δίτροχο**, και γέλασα πολύ.

Αντί για ακριβή αντιστοιχία λέξεων, θα χρησιμοποιήσουμε σημασιολογικές ενσωματώσεις!

Ας θυμηθούμε τα προηγούμενα...

Εσωτερικό Γινόμενο

Το Εσωτερικό Γινόμενο $\langle \boldsymbol{W}, \boldsymbol{X} \rangle$ είναι μεγάλο όταν το W και το X:

- «Μοιάζουν»
- Είναι κοντά στον γεωμετρικό χώρο
- Σχηματίζουν μικρή γωνία $\angle \boldsymbol{W}\mathbf{X}$

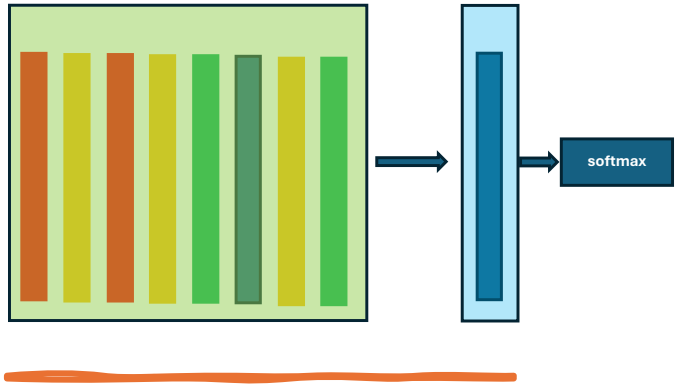

Δεδομένα {φασκωλόμυς, κοάλα, καγκουρό}

Convolutional Νευρωνικό Δίκτυο

Convolutional Νευρωνικό Δίκτυο

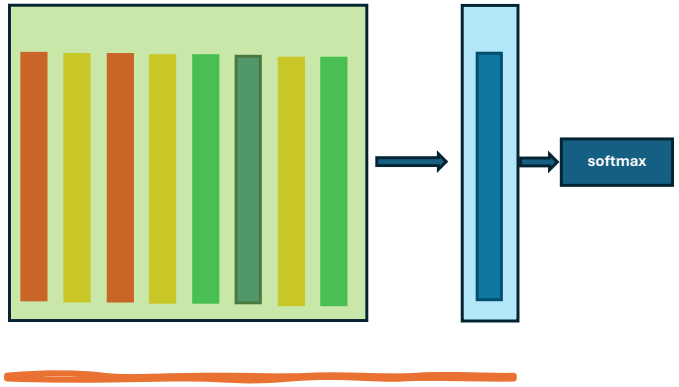

Δεδομένα {φασκωλόμυς, κοάλα, καγκουρό}

Convolutional Νευρωνικό Δίκτυο

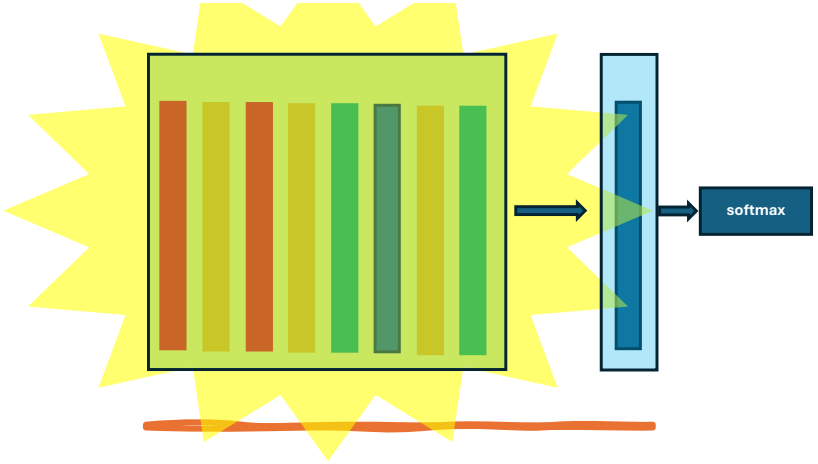

Δεδομένα {φασκωλόμυς, κοάλα, καγκουρό}

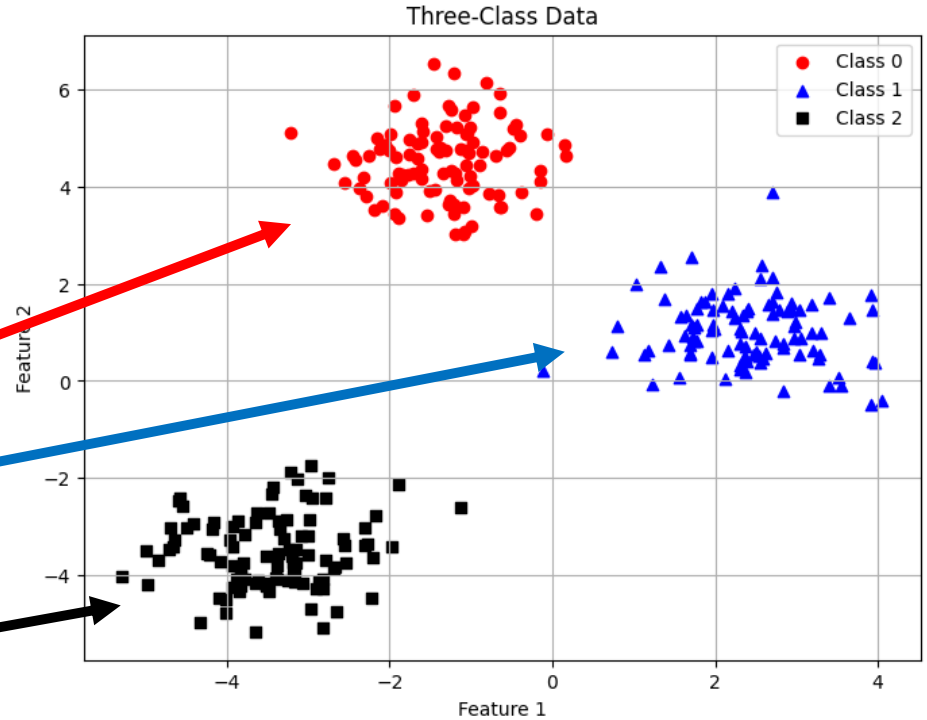

Convolutional Νευρωνικό Δίκτυο

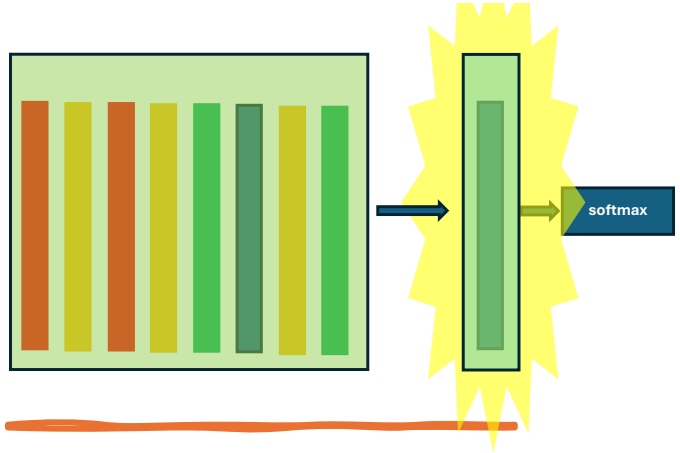

Δεδομένα {φασκωλόμυς, κοάλα, καγκουρό}

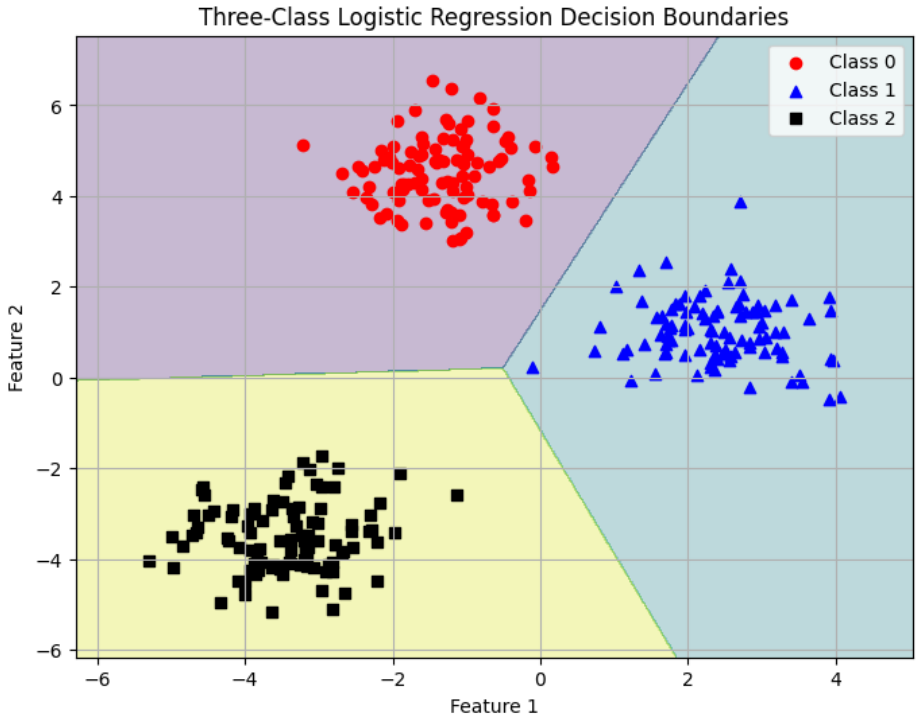

Embeddings (Ενσωματώσεις)

Εικόνες (πίξελ)

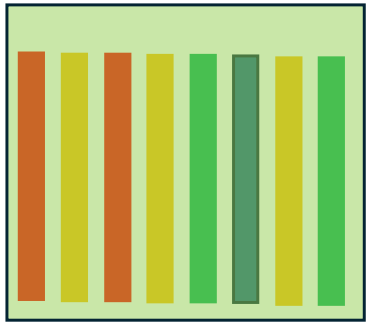

Embeddings

Δεδομένα {φασκωλόμυς, κοάλα, καγκουρό}

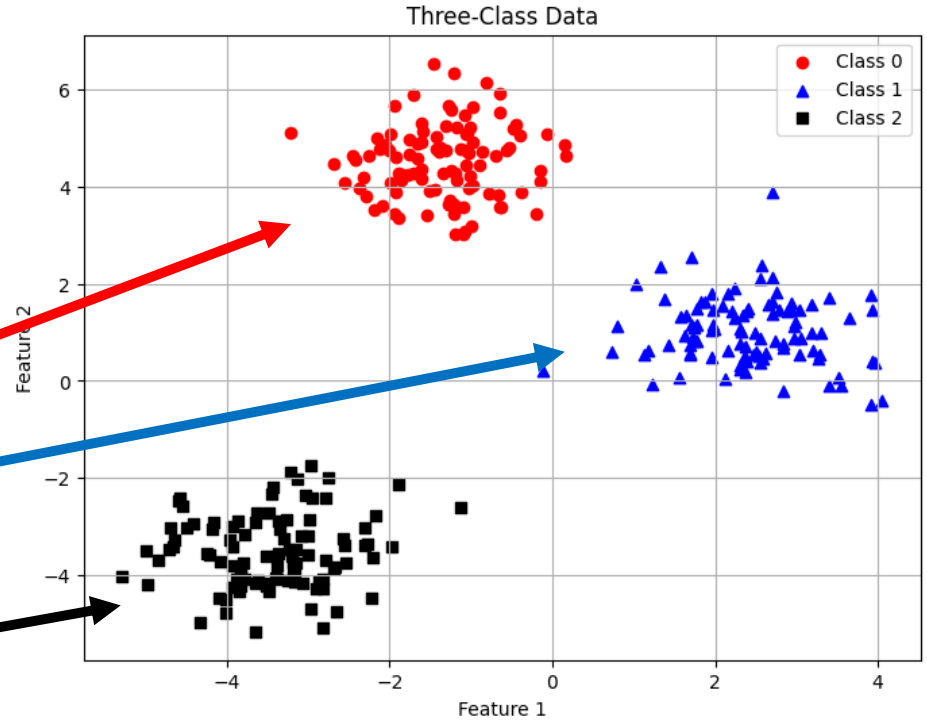

Embeddings: η απόσταση στον γεωμετρικό χώρο αντικαθιστά την απόσταση που αντιλαμβανόμαστε

Embeddings: η απόσταση στον γεωμετρικό χώρο αντικαθιστά την απόσταση που αντιλαμβανόμαστε

Embeddings/Ενσωματώσεις: η απόσταση στον γεωμετρικό χώρο αντικαθιστά την «σημασιολογική» απόσταση

Πίξελ προς πίξελ δεν μοιάζουν καθόλου οι δύο εικόνες. «Μοιάζουν» επειδή απεικονίζου και οι δύο καγκουρό

Embeddings/Ενσωματώσεις: η απόσταση στον γεωμετρικό χώρο αντικαθιστά την «σημασιολογική» απόσταση

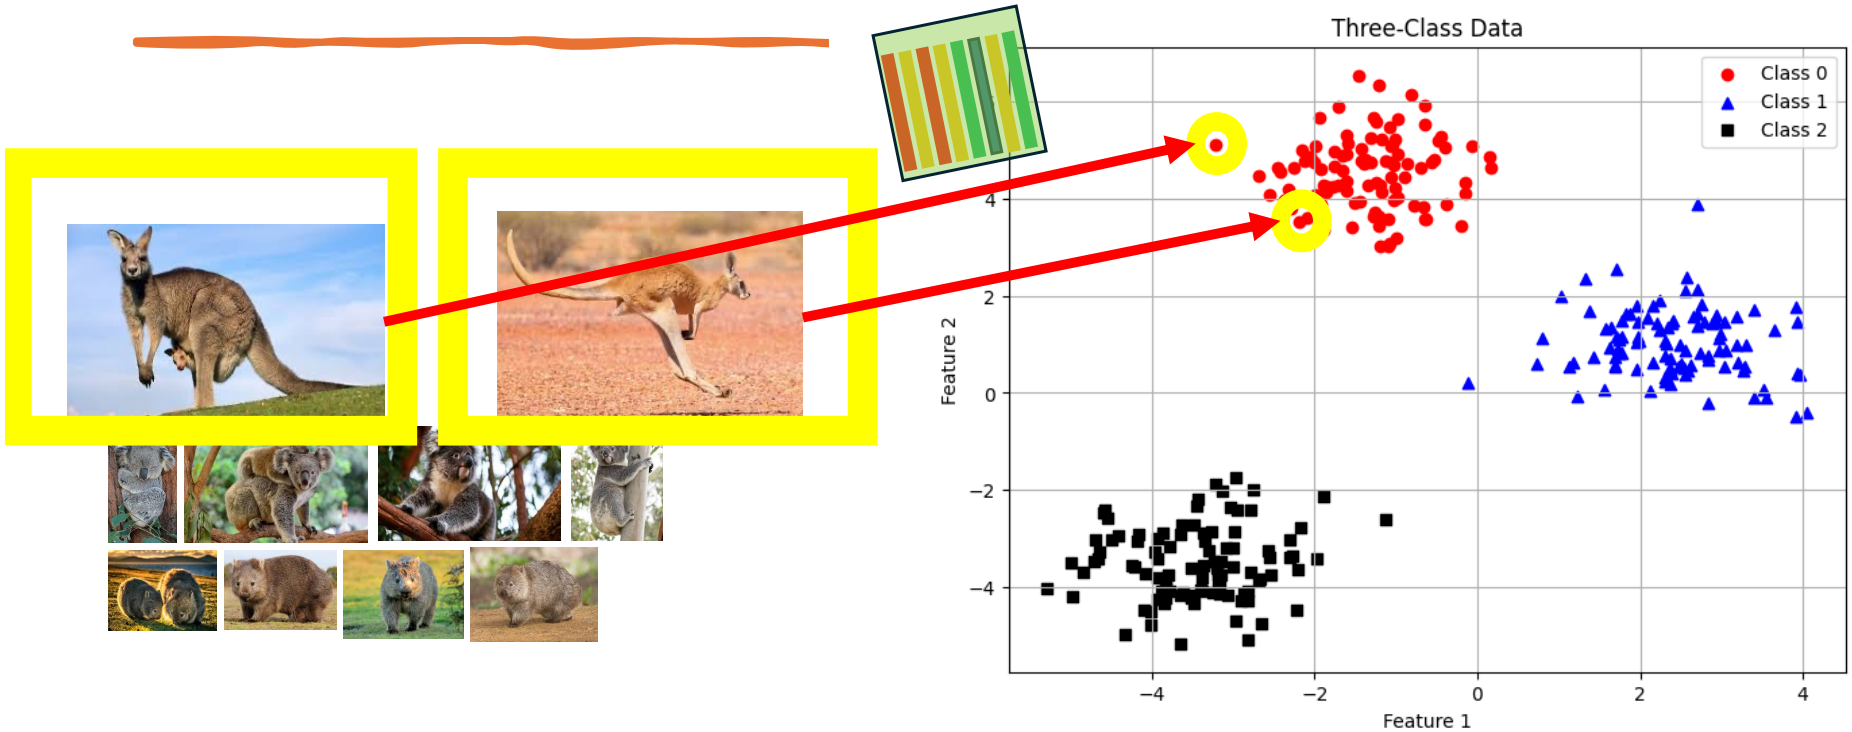

Embeddings/Ενσωματώσεις: η απόσταση στον γεωμετρικό χώρο αντικαθιστά την «σημασιολογική» απόσταση

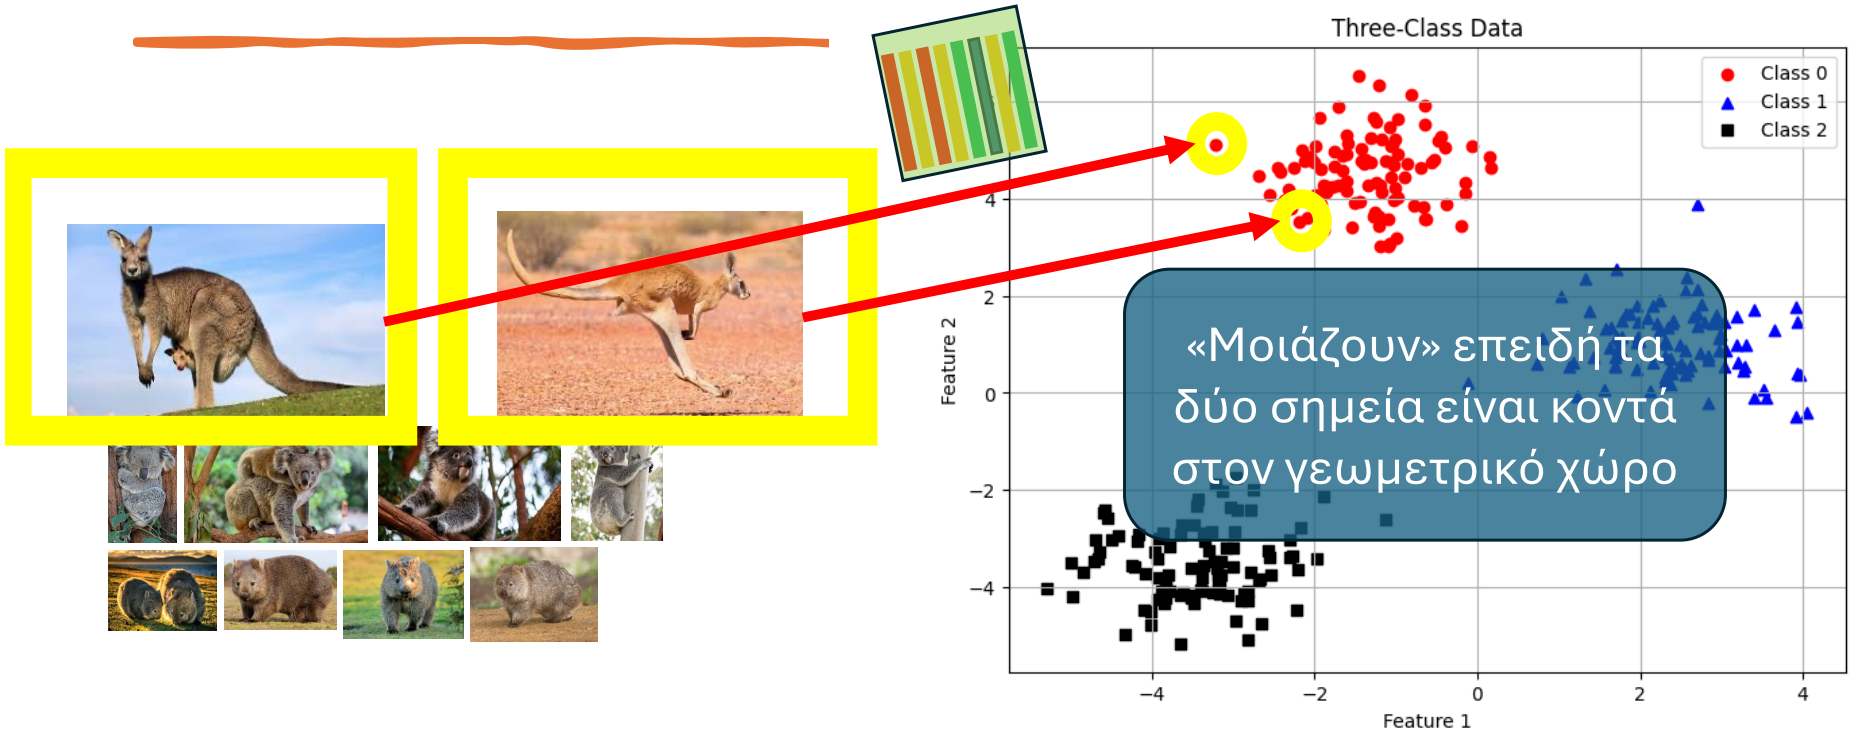

Embeddings/Ενσωματώσεις: η απόσταση στον γεωμετρικό χώρο αντικαθιστά την «σημασιολογική» απόσταση

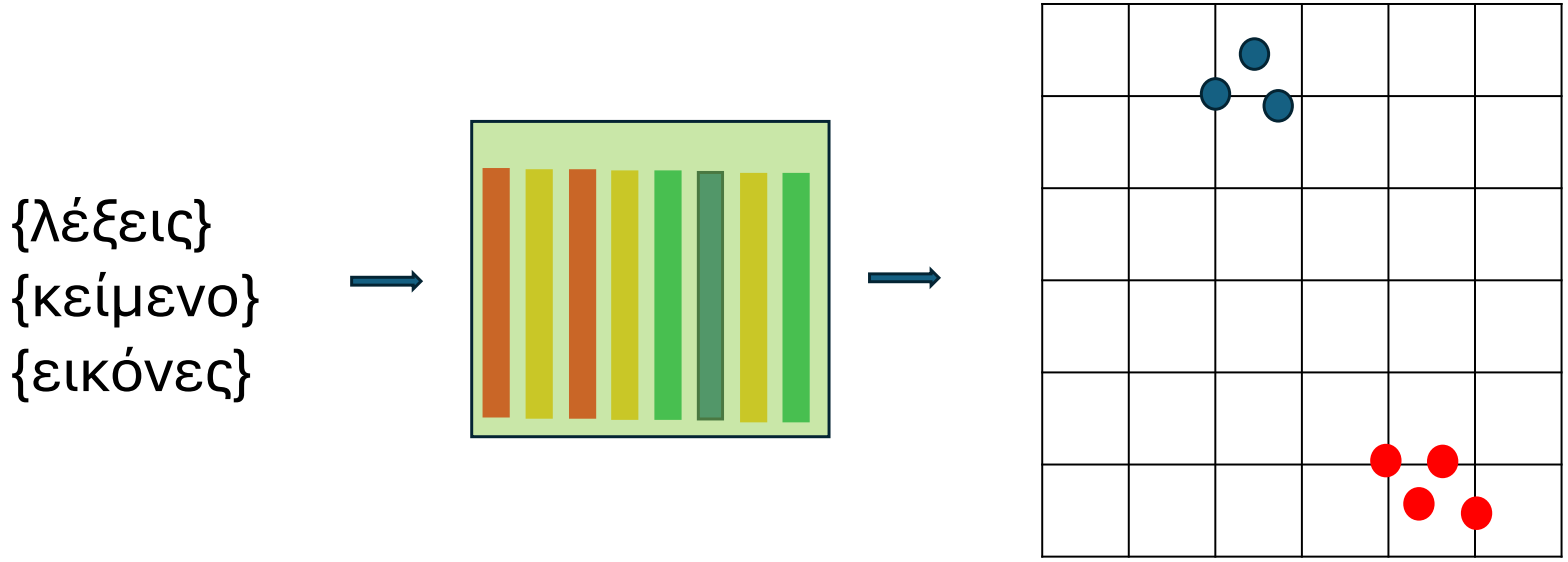

Embeddings/Ενσωματώσεις: η απόσταση στον γεωμετρικό χώρο αντικαθιστά την «σημασιολογική» απόσταση

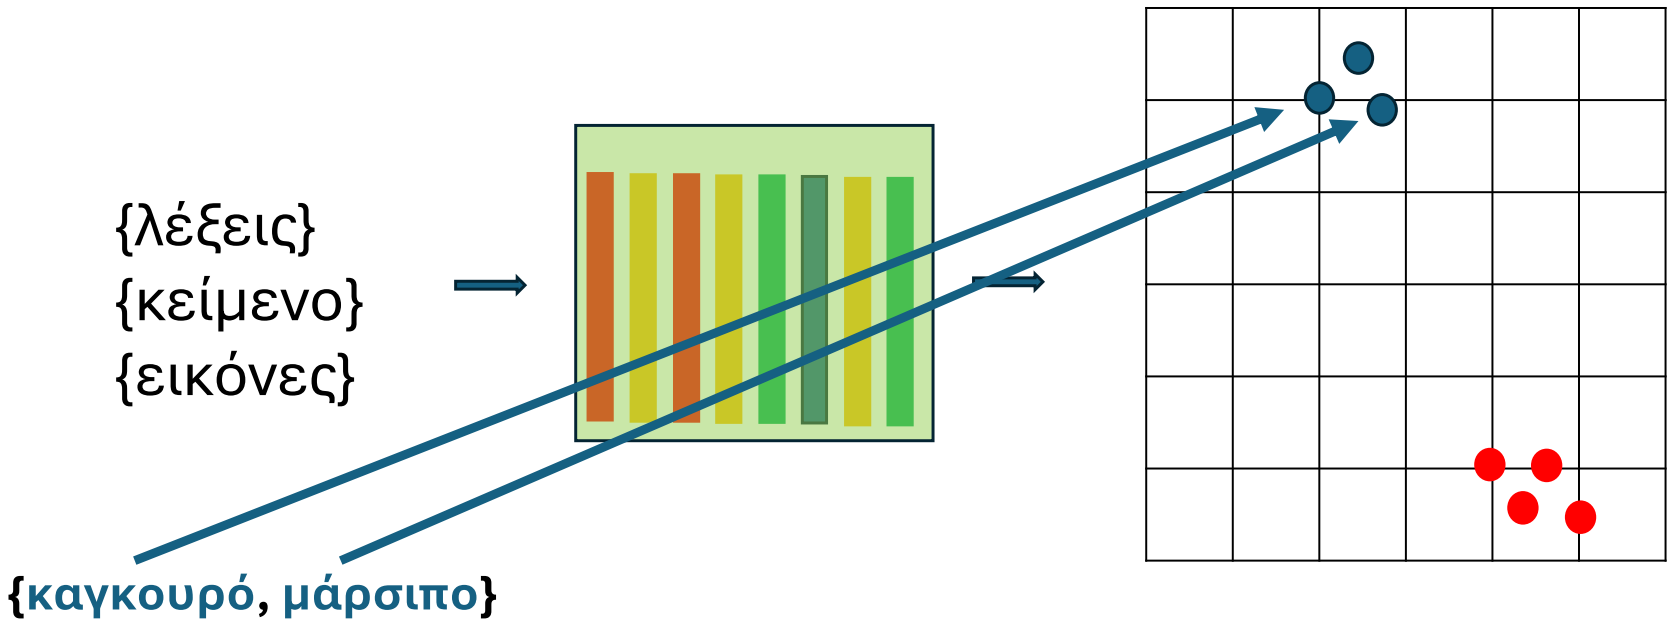

Embeddings/Ενσωματώσεις: η απόσταση στον γεωμετρικό χώρο αντικαθιστά την «σημασιολογική» απόσταση

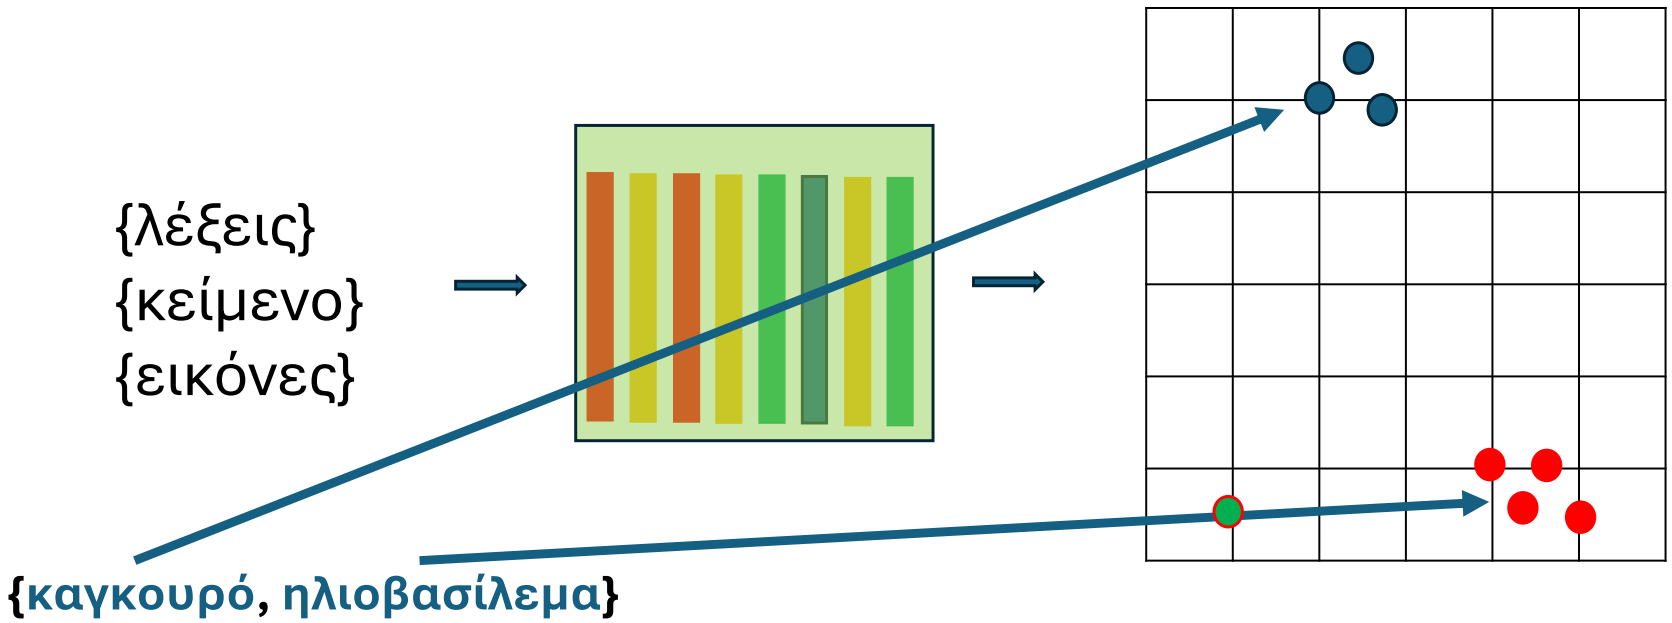

Embeddings/Ενσωματώσεις: η απόσταση στον γεωμετρικό χώρο αντικαθιστά την «σημασιολογική» απόσταση

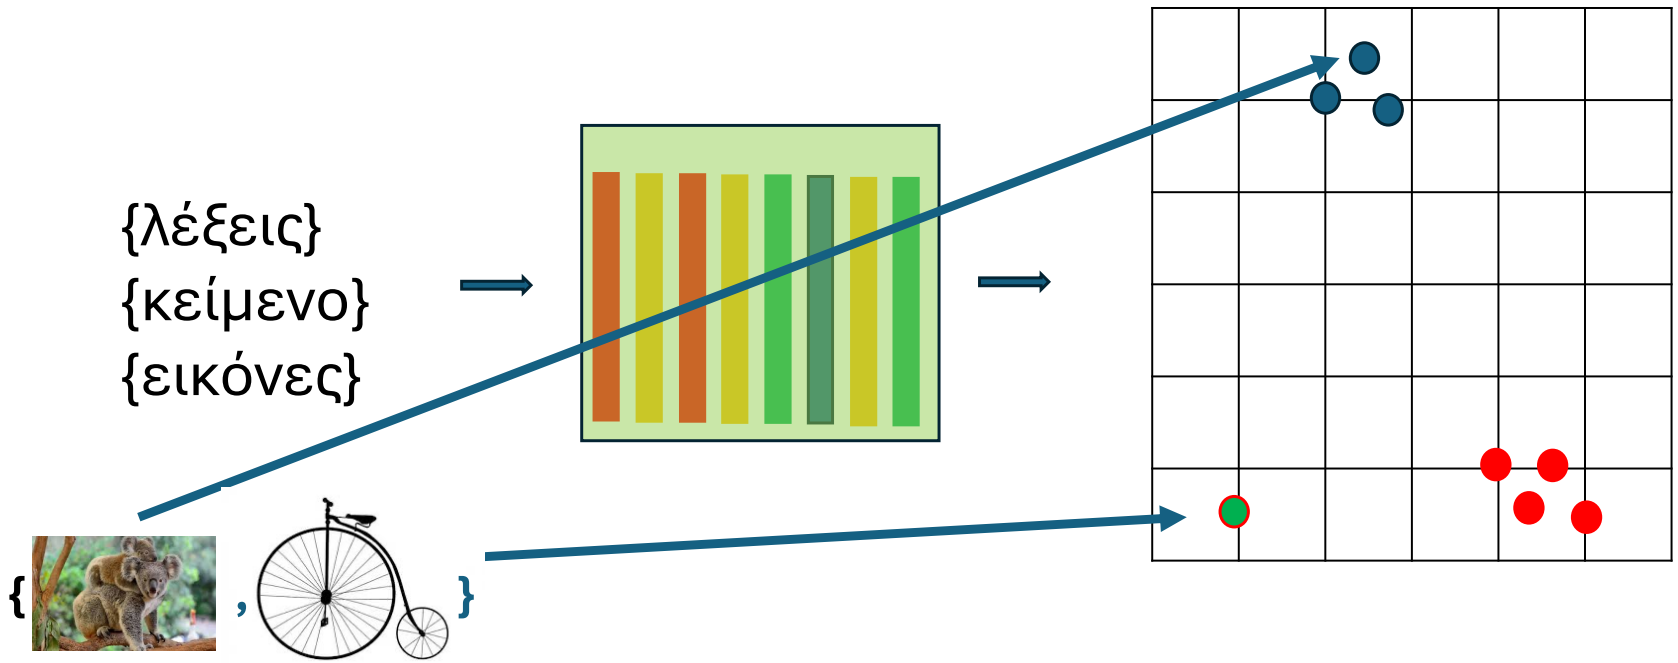

Embeddings/Ενσωματώσεις: η απόσταση στον γεωμετρικό χώρο αντικαθιστά την «σημασιολογική» απόσταση

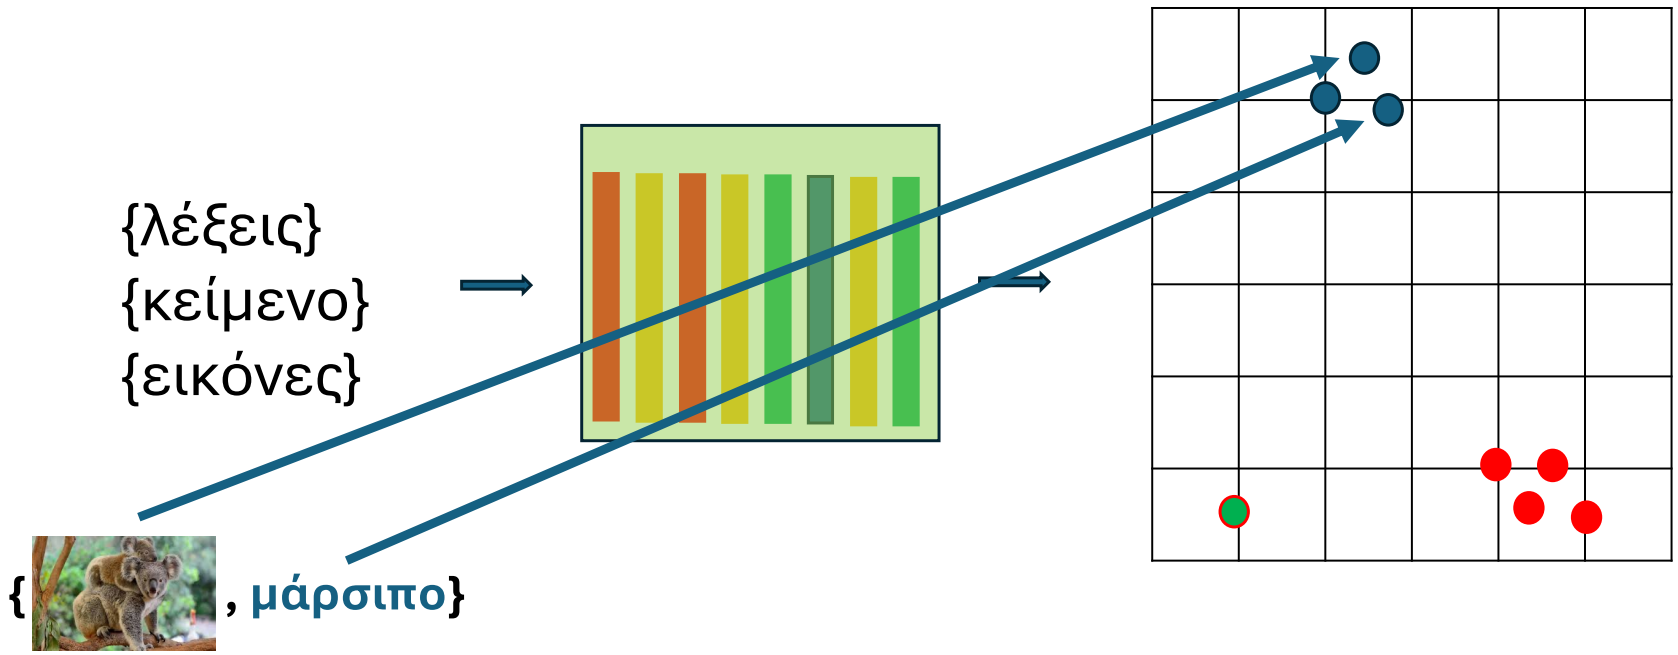

Embeddings/Ενσωματώσεις: η απόσταση στον γεωμετρικό χώρο αντικαθιστά την «σημασιολογική» απόσταση

{λέξεις}
{κείμενο}
{εικόνες}

{ , **μάρσιπο**}

Πώς δημιουργούμε καλές ενσωματώσεις (embeddings) για εικόνες, λέξεις, κείμενο, ή για δεδομένα που συνδυάζουν και τις δύο μορφές;

Word2Vec*: σημασιολογικές ενσωματώσεις λέξεων

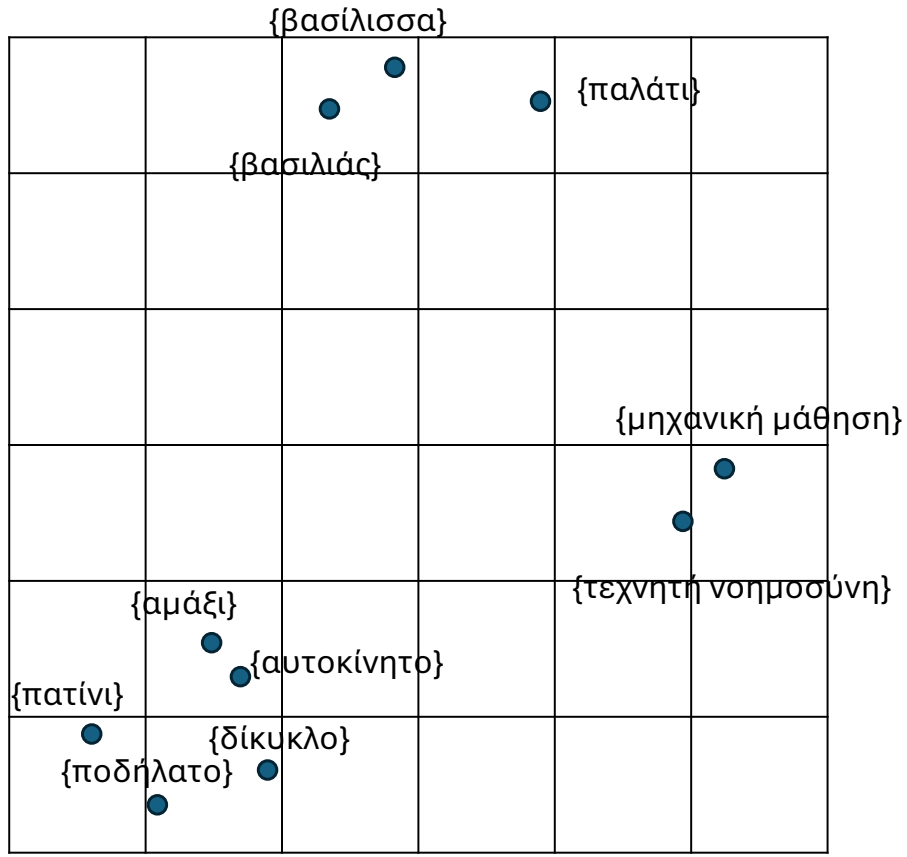

*Mikolov, T., Chen, K., Corrado, G. and Dean, J., 2013. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*

Word2Vec*: σημασιολογικές ενσωματώσεις λέξεων

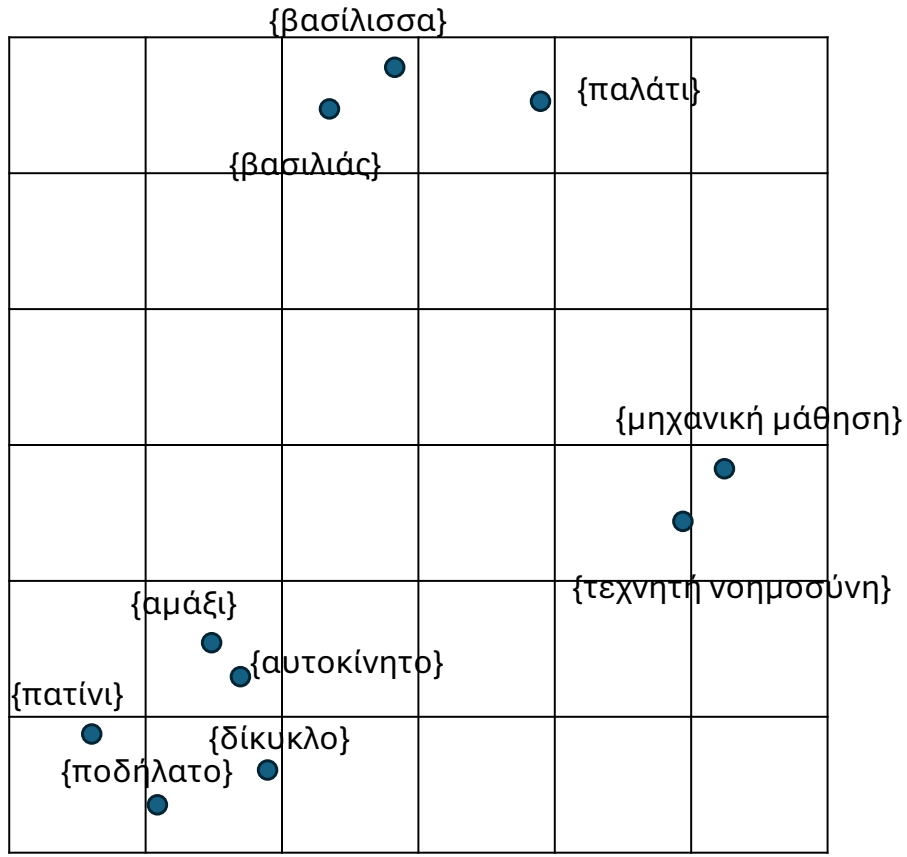

*Mikolov, T., Chen, K., Corrado, G. and Dean, J., 2013. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*

Πώς θα πετύχουμε τον στόχο μας;

1. Εάν έχουμε 30.000 λέξεις, έχουμε 900.000.000 ζεύγη. Δεν είναι πρακτικό (εφικτό) να χαρακτηρίσουμε όλα αυτά τα ζεύγη «με το χέρι».
2. Και να είχαμε 900.000.000 επιθυμητές γωνίες (αποστάσεις) $\theta_{\alpha\beta}$ από την λέξη α στην λέξη β, πως θα βρίσκαμε διανύσματα v_α, v_β ώστε $\angle v_\alpha v_\beta \approx \theta_{\alpha\beta}$ για κάθε ζεύγος (α,β);

*Mikolov, T., Chen, K., Corrado, G. and Dean, J., 2013. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*

Η βασική ιδέα: self-supervision

- Θα λύσουμε ταυτόχρονα και τα δύο αυτά τα προβλήματα με την ευφυή ιδέα του **self-supervision**
- Θα εκμεταλλευτούμε μια σχεδόν ανεξάντλητη πηγή: το κείμενο στο διαδίκτυο
- Πρέπει να δημιουργήσουμε ένα πρόβλημα που να υπάγεται στο πρότυπο της *επιτηρούμενης μάθησης*

Πώς θα πετύχουμε τον στόχο μας;

1. Εάν έχουμε 30.000 λέξεις, έχουμε 900.000.000 ζεύγη. Δεν είναι πρακτικό (εφικτό) να χαρακτηρίσουμε όλα αυτά τα ζεύγη «με το χέρι».
2. Και να είχαμε 900.000.000 επιθυμητές γωνίες (αποστάσεις) $\theta_{\alpha\beta}$ από την λέξη α στην λέξη β, πως θα βρίσκαμε διανύσματα v_α, v_β ώστε $\angle v_\alpha v_\beta \approx \theta_{\alpha\beta}$ για κάθε ζεύγος (α,β);

Επιτηρούμενη Μάθηση

Επιτηρούμενη Μάθηση:
Βλέπουμε *n* παραδείγματα:
(X_1,y_1), (X_2,y_2), ..., (X_n,y_n)

Μαθαίνουμε τη σχέση X → y, δηλαδή μαθαίνουμε συνάρτηση h(X) που να είναι «κοντά» στο y.

Επιτηρούμενη Μάθηση

Επιτηρούμενη Μάθηση:
Βλέπουμε *n* παραδείγματα:
$(X_1,y_1), (X_2,y_2), ..., (X_n,y_n)$

→ y,
τηση
το y.

Το αρχικό μας πρόβλημα είναι να βρούμε σημασιολογικές ενσωματώσεις. Για να χρησιμοποιήσουμε όλα τα εργαλεία της επιτηρούμενης μάθησης πρέπει να διαμορφώσουμε το πρόβλημά μας στη σωστή μορφή.

Χρειαζόμαστε n «παραδείγματα» (X,y)

Η βασική ιδέα: self-supervision

«Αποχαιρετά τη γη, φεύγει.
Περνάει την παγωμένη θάλασσα,
τρικυμία ξεσπάει, συντρίβεται το
καράβι σε άγρια χιονισμένα βράχια.»

Η βασική ιδέα: self-supervision

*«**Αποχαιρετά** τη **γη**, φεύγει.*
Περνάει την παγωμένη θάλασσα,
τρικυμία ξεσπάει, συντρίβεται το
καράβι σε άγρια χιονισμένα βράχια.»

X_1 = (Αποχαιρετά, γη), y_1 = P(**γη** ακολουθεί **αποχαιρετά**)

Η βασική ιδέα: self-supervision

*«**Αποχαιρετά** τη **γη**, φεύγει.*
Περνάει την παγωμένη θάλασσα,
τρικυμία ξεσπάει, συντρίβεται το
καράβι σε άγρια χιονισμένα βράχια.»

Υπολογίζεται από το συνολικό σώμα κειμένων που χρησιμοποιούμε

X_1 = (Αποχαιρετά, γη), y_1 = P(**γη** ακολουθεί **αποχαιρετά**)

Η βασική ιδέα: self-supervision

«Αποχαιρετά τη γη, φεύγει.
*Περνάει την **παγωμένη θάλασσα**,*
τρικυμία ξεσπάει, συντρίβεται το
καράβι σε άγρια χιονισμένα βράχια.»

Υπολογίζεται από το συνολικό σώμα κειμένων που χρησιμοποιούμε

X_1 = (Αποχαιρετά, γη), y_1 = P(**γη** ακολουθεί **αποχαιρετά**)

X_2 = (*παγωμένη*, *θάλασσα*), y_2 = P(**θάλασσα** ακολουθεί **παγωμένη**)

Η βασική ιδέα: self-supervision

«Αποχαιρετά τη γη, φεύγει.
Περνάει την παγωμένη θάλασσα,
***τρικυμία ξεσπάει, συντρίβεται** το*
***καράβι** σε άγρια χιονισμένα βράχια.»*

Υπολογίζεται από το συνολικό σώμα κειμένων που χρησιμοποιούμε

X_1 = (Αποχαιρετά, γη), y_1 = P(**γη** ακολουθεί **αποχαιρετά**)

X_2 = (*παγωμένη*, *θάλασσα*), y_2 = P(**θάλασσα** ακολουθεί **παγωμένη**)

X_3 = (τρικυμία, ξεσπάει), y_3 = P(**ξεσπάει** ακολουθεί **τρικυμία**)

X_4 = (*συντρίβεται*, *καράβι*), y_4 = P(**καράβι** ακολουθεί **συντρίβεται**)

Η βασική ιδέα: self-supervision

«Η κόρη της αγαπούσε πολύ { τις γάτες / τα σκυλιά / το παγωτό } »

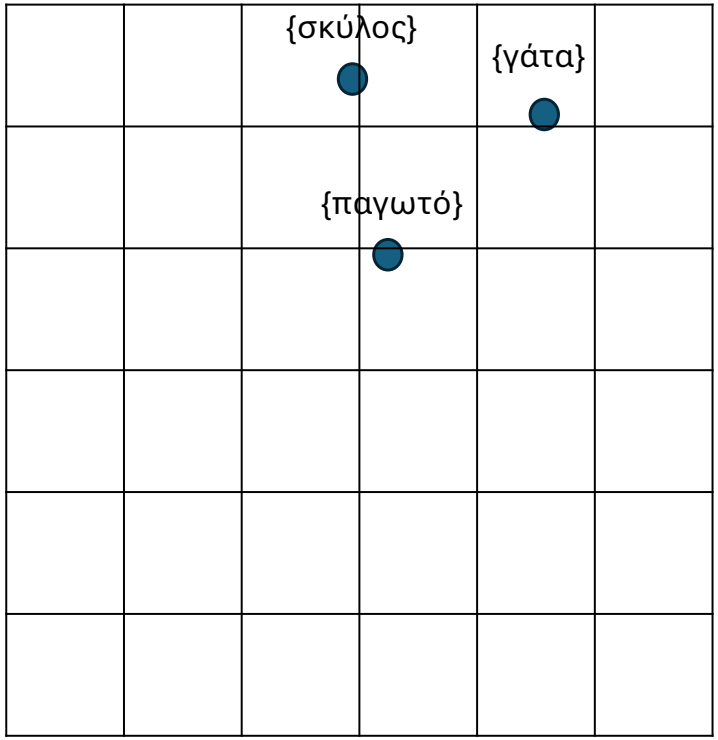

Η βασική ιδέα: self-supervision

«Η κόρη της αγαπούσε πολύ { τις γάτες / τα σκυλιά / το παγωτό } »

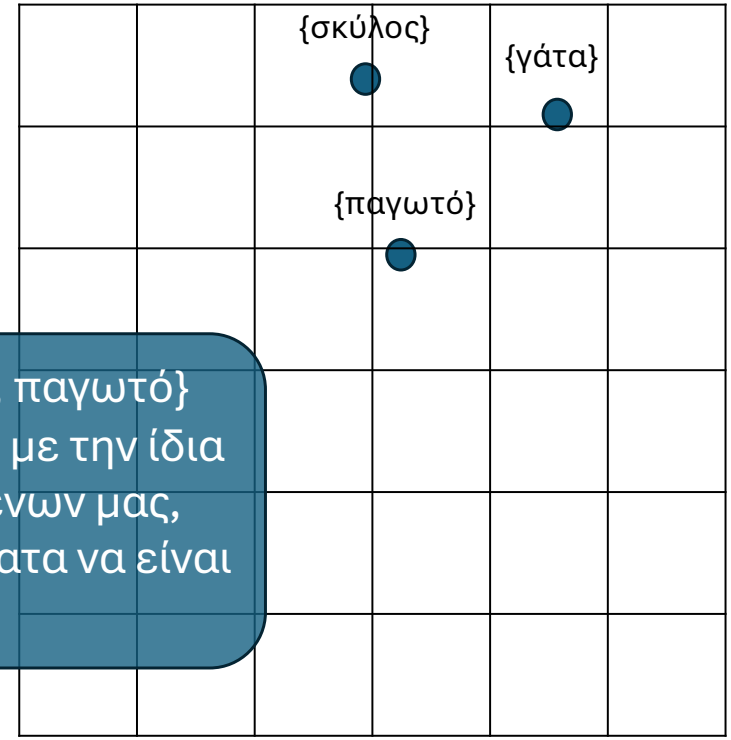

Εάν οι λέξεις {γάτα, σκύλος, παγωτό} ακολουθούν τη λέξη {αγαπώ} με την ίδια συχνότητα στο σώμα κειμένων μας, θέλουμε τα ανάλογα διανύσματα να είναι κοντά στο χώρο

Η βασική ιδέα: self-supervision

«Η κόρη της αγαπούσε πολύ { τις γάτες / τα σκυλιά / το παγωτό } »

«Πήγε { την γάτα / τον σκύλο / το παγωτό } στον κτηνίατρο»

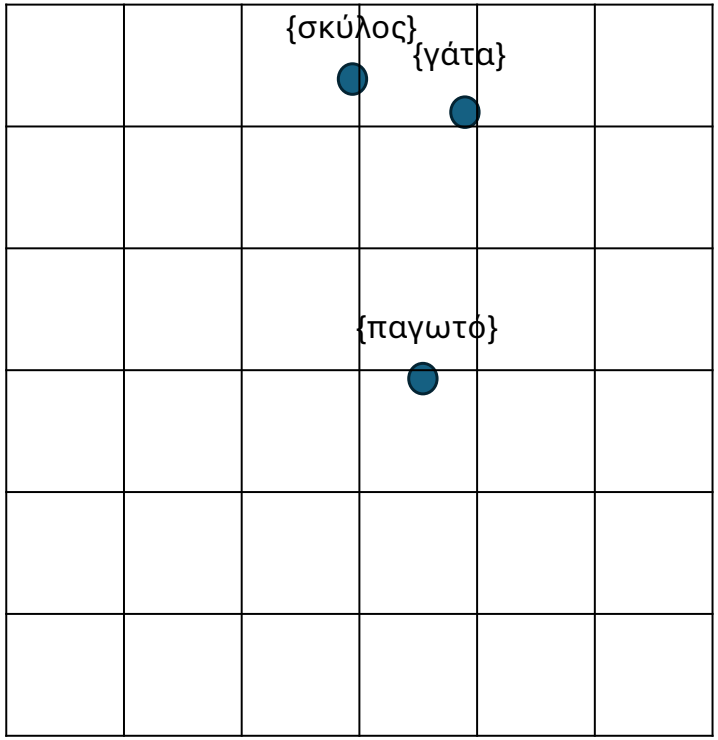

Η βασική ιδέα: self-supervision

«Η κόρη της αγαπούσε πολύ { τις γάτες / τα σκυλιά / το παγωτό }»

«Πήγε { την γάτα / τον σκύλο / το παγωτό } στο κτηνίατρο

Οι λέξεις {γάτα, σκύλος, παγωτό} ΔΕΝ προηγούνται της λέξης {κτηνίατρος} με την ίδια συχνότητα στο σώμα κειμένων μας. Τα ανάλογα διανύσματα δεν πρέπει να είναι κοντά μεταξύ τους στον χώρο

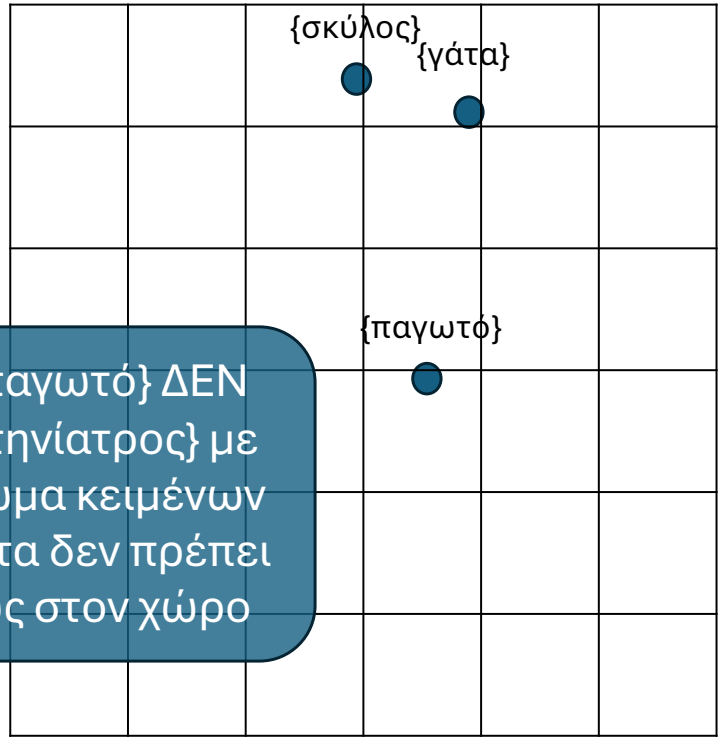

Η βασική ιδέα: self-supervision

«Η κόρη της αγαπούσε πολύ { τις γάτες / τα σκυλιά / το παγωτό }»

«Πήγε { την γάτα / τον σκύλο / το παγωτό } στον κτηνίατρο»

«Βγήκε βόλτα με { την γάτα / τον σκύλο / το παγωτό }»

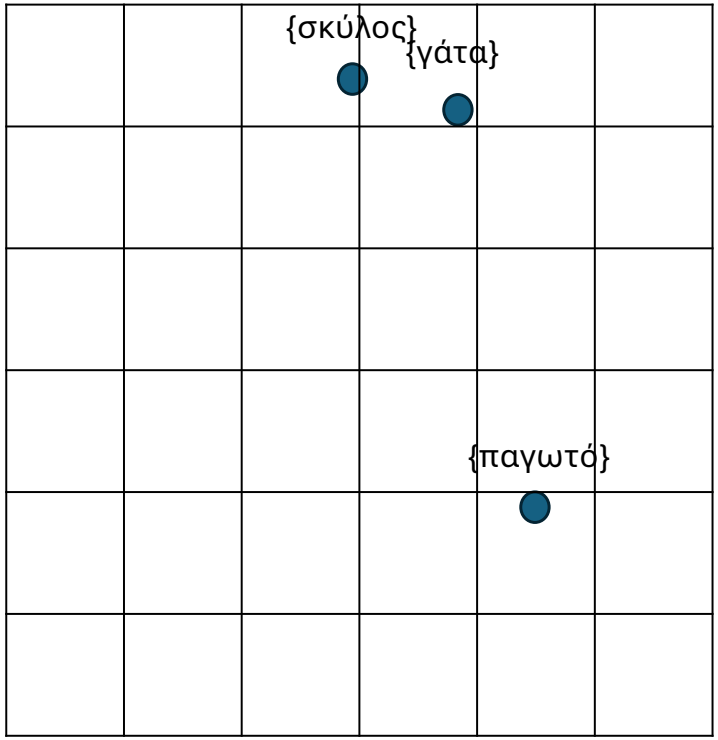

Η βασική ιδέα: self-supervision

«Η κόρη της αγαπούσε πολύ { τις γάτες / τα σκυλιά / το παγωτό }»

«Πήγε { την γάτα / τον σκύλο / το παγωτό } στον κτηνιατρό»

«Βγήκε βόλτα με { την γάτα / τον σκύλο / το παγωτό }»

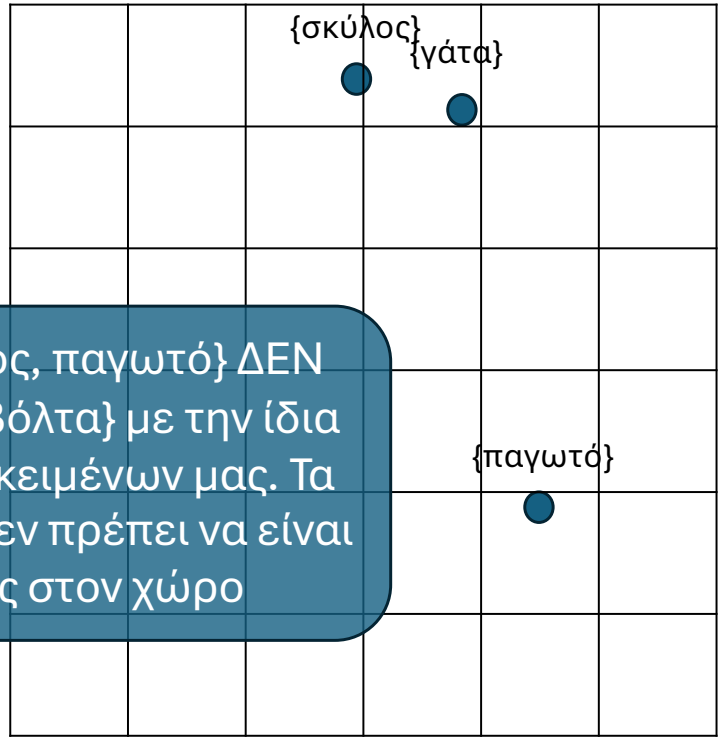

Οι λέξεις {γάτα, σκύλος, παγωτό} ΔΕΝ ακολουθούν τη λέξη {βόλτα} με την ίδια συχνότητα στο σώμα κειμένων μας. Τα ανάλογα διανύσματα δεν πρέπει να είναι κοντά μεταξύ τους στον χώρο

Self-supervision & Λογιστική Παλινδρόμηση

σώμα κειμένων → $\{(X,y) = ((\text{λέξη}_\alpha, \text{λέξη}_\beta), p_{\alpha\beta})\}$

Self-supervision & Λογιστική Παλινδρόμηση

σώμα κειμένων → {(X,y) = ((λέξη$_\alpha$, λέξη$_\beta$), p$_{\alpha\beta}$)}

Για κάθε λέξη {λέξη$_\alpha$} θέλουμε να βρούμε διανύσματα $\mathbf{u_\alpha}$, $\mathbf{v_\alpha}$ ώστε:

$$p_{\alpha\beta} \approx \frac{\exp(u_\alpha^T v_\beta)}{\sum_{\alpha' \in A} \exp(u_{\alpha'} v_\beta)}$$

Self-supervision & Λογιστική Παλινδρόμηση

σώμα κειμένων → {(X,y) = ((λέξη$_\alpha$, λέξη$_\beta$), p$_{\alpha\beta}$)}

Για κάθε λέξη {λέξη$_\alpha$} θέλουμε να βρούμε διανύσματα $\mathbf{u_\alpha}$, $\mathbf{v_\alpha}$ ώστε:

$$p_{\alpha\beta} \approx \frac{\exp(u_\alpha^T v_\beta)}{\sum_{\alpha' \in A} \exp(u_{\alpha'} v_\beta)}$$

Υπολογίζεται από το κείμενο

Υπολογίζεται από τις ενσωματώσεις

Self-supervision & Λογιστική Παλινδρόμηση

σώμα κειμένων → {(X,y) = ((λέξη$_\alpha$, λέξη$_\beta$), p$_{\alpha\beta}$)}

Για κάθε λέξη {λέξη$_\alpha$} θέλουμε να βρούμε διανύσματα $\mathbf{u_\alpha}$, $\mathbf{v_\alpha}$ ώστε:

$$p_{\alpha\beta} \approx \frac{\exp(u_\alpha^T v_\beta)}{\sum_{\alpha' \in A} \exp(u_{\alpha'} v_\beta)}$$

softmax

Νευρωνικό Δίκτυο για το Word2Vec

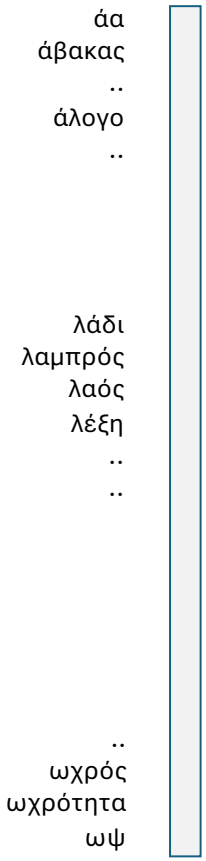

Νευρωνικό Δίκτυο για το Word2Vec

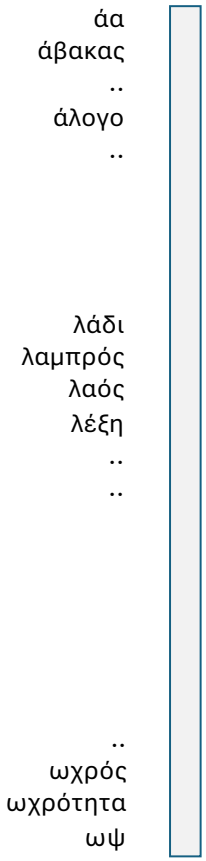

Αρχίζουμε με όλες τις λέξεις στο λεξικό μας – το σύνολο λέξεων στα κείμενά μας

Νευρωνικό Δίκτυο για το Word2Vec

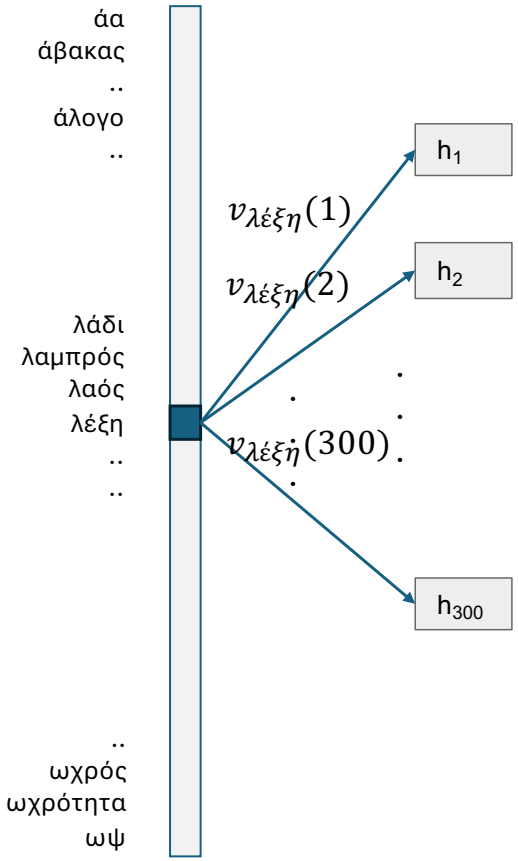

Νευρωνικό Δίκτυο για το Word2Vec

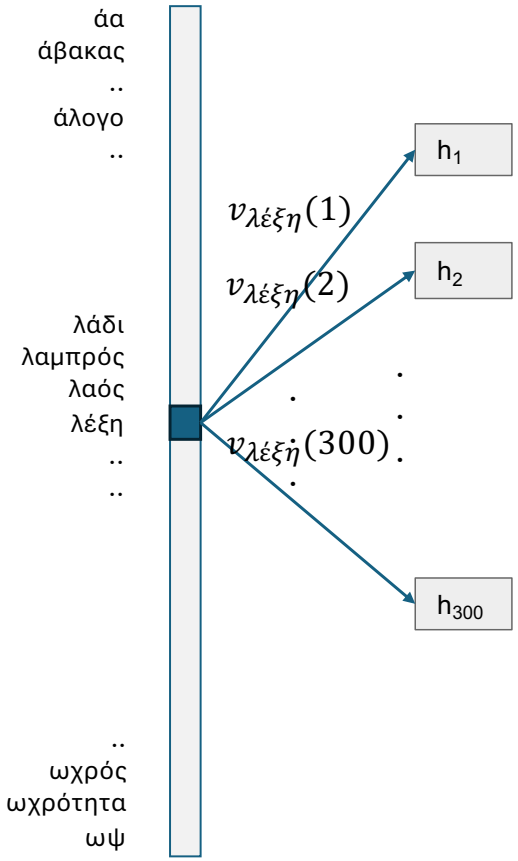

$$v_{\lambda\acute{\varepsilon}\xi\eta} = \begin{pmatrix} v_{\lambda\acute{\varepsilon}\xi\eta}(1) \\ v_{\lambda\acute{\varepsilon}\xi\eta}(2) \\ \\ v_{\lambda\acute{\varepsilon}\xi\eta}(300) \end{pmatrix}$$

Ενσωμάτωση (embedding) ως δεύτερη (ακόλουθη) λέξη σε 300 διαστάσεις.

Νευρωνικό Δίκτυο για το Word2Vec

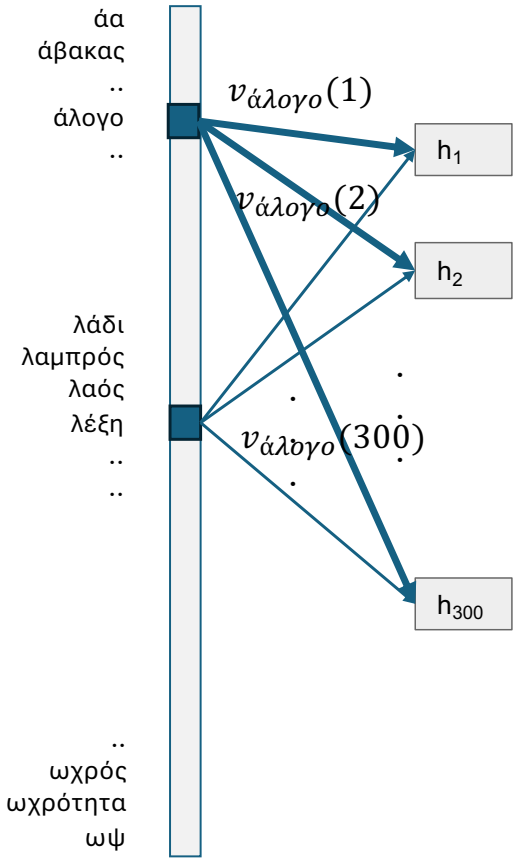

$$v_{\text{άλογο}} = \begin{pmatrix} v_{\text{άλογο}}(1) \\ v_{\text{άλογο}}(2) \\ \\ v_{\text{άλογο}}(300) \end{pmatrix}$$

Ενσωμάτωση (embedding) ως δεύτερη (ακόλουθη) λέξη σε 300 διαστάσεις.

Νευρωνικό Δίκτυο για το Word2Vec

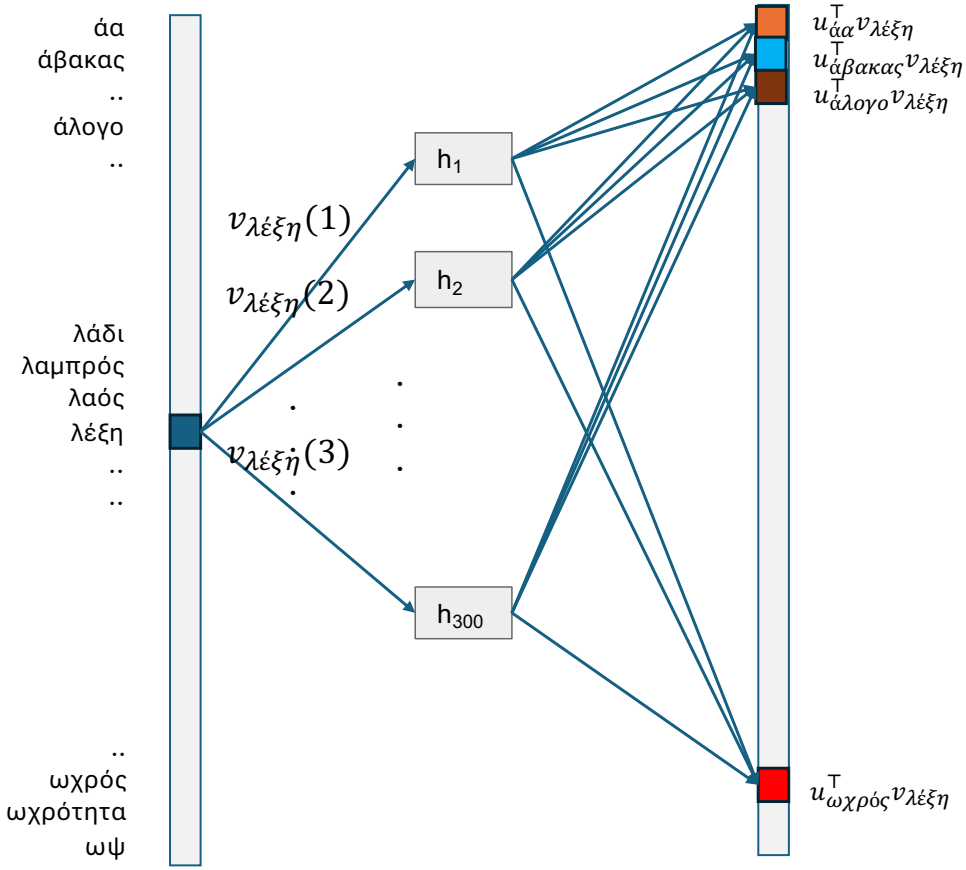

Νευρωνικό Δίκτυο για το Word2Vec

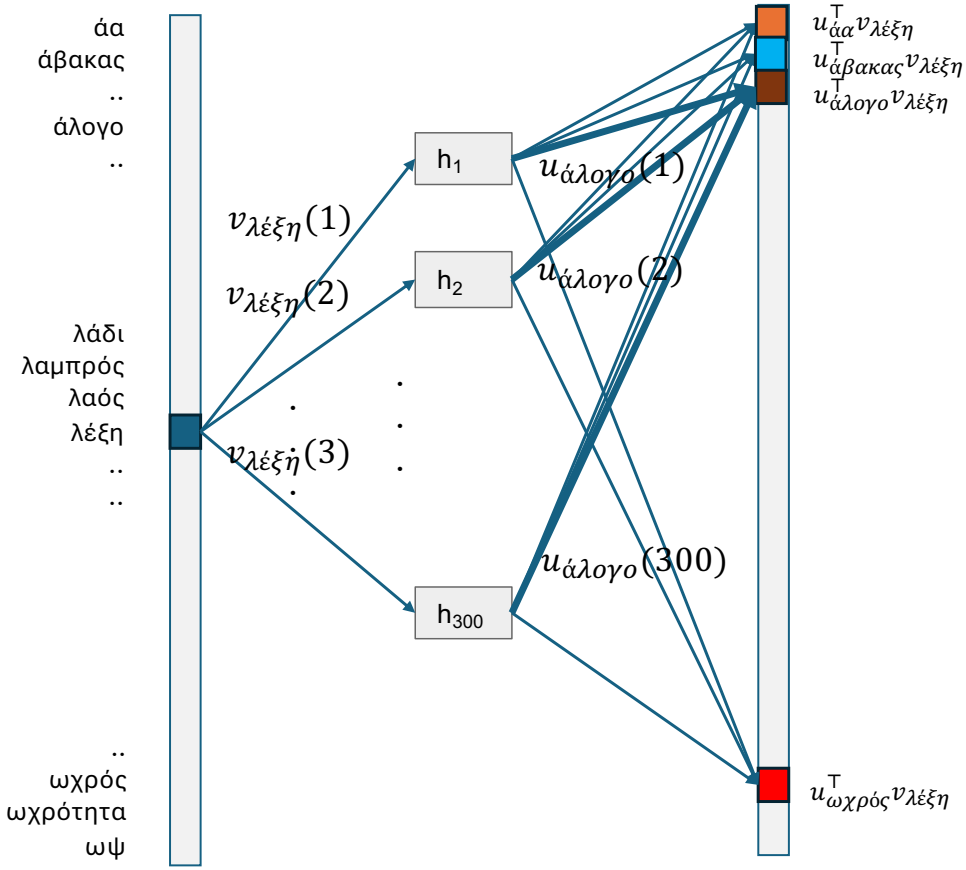

$$v_{\text{άλογο}} = \begin{pmatrix} v_{\text{άλογο}}(1) \\ v_{\text{άλογο}}(2) \\ \\ v_{\text{άλογο}}(300) \end{pmatrix}$$

Ενσωμάτωση (embedding) ως πρώτη (προηγούμενη) λέξη, πάλι σε 300 διαστάσεις

Νευρωνικό Δίκτυο για το Word2Vec

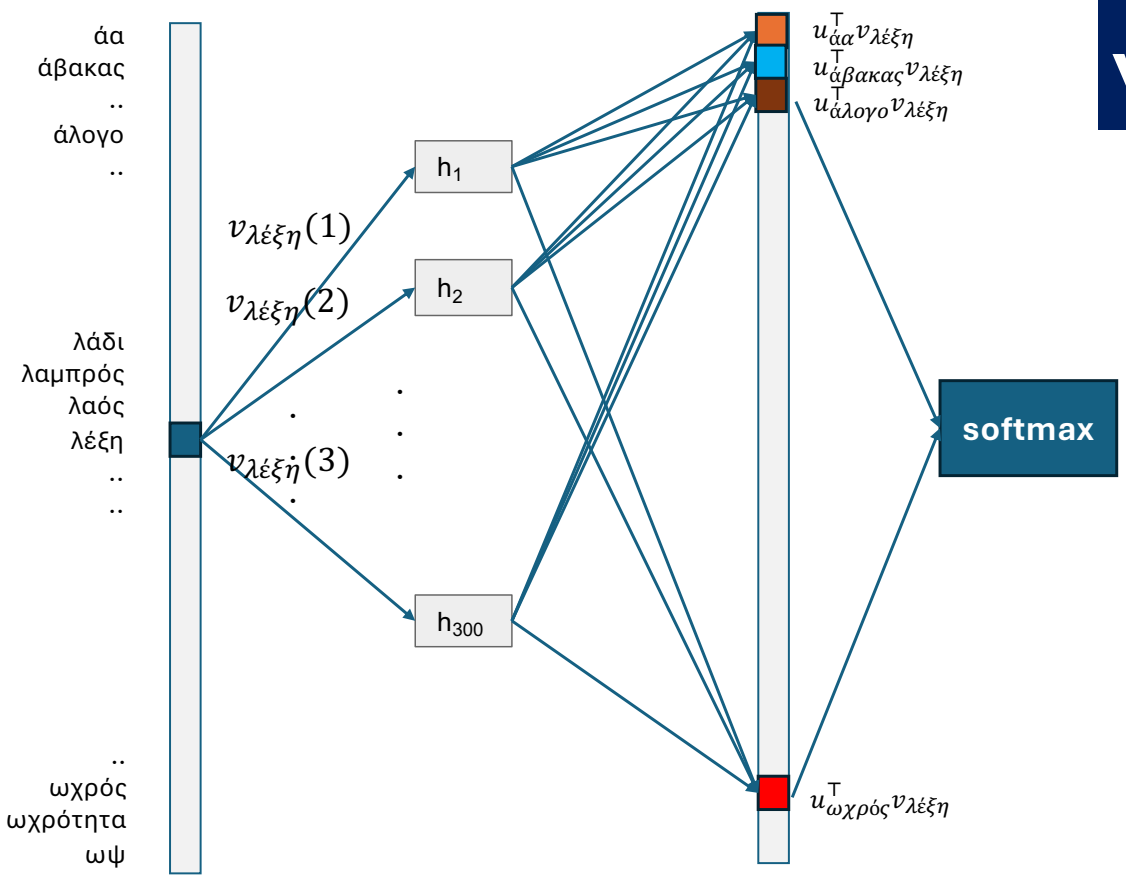

$$\frac{\exp(u_\alpha^T v_\beta)}{\sum_{\alpha' \in A} \exp(u_{\alpha'} v_\beta)}$$

Νευρωνικό Δίκτυο για το Word2Vec

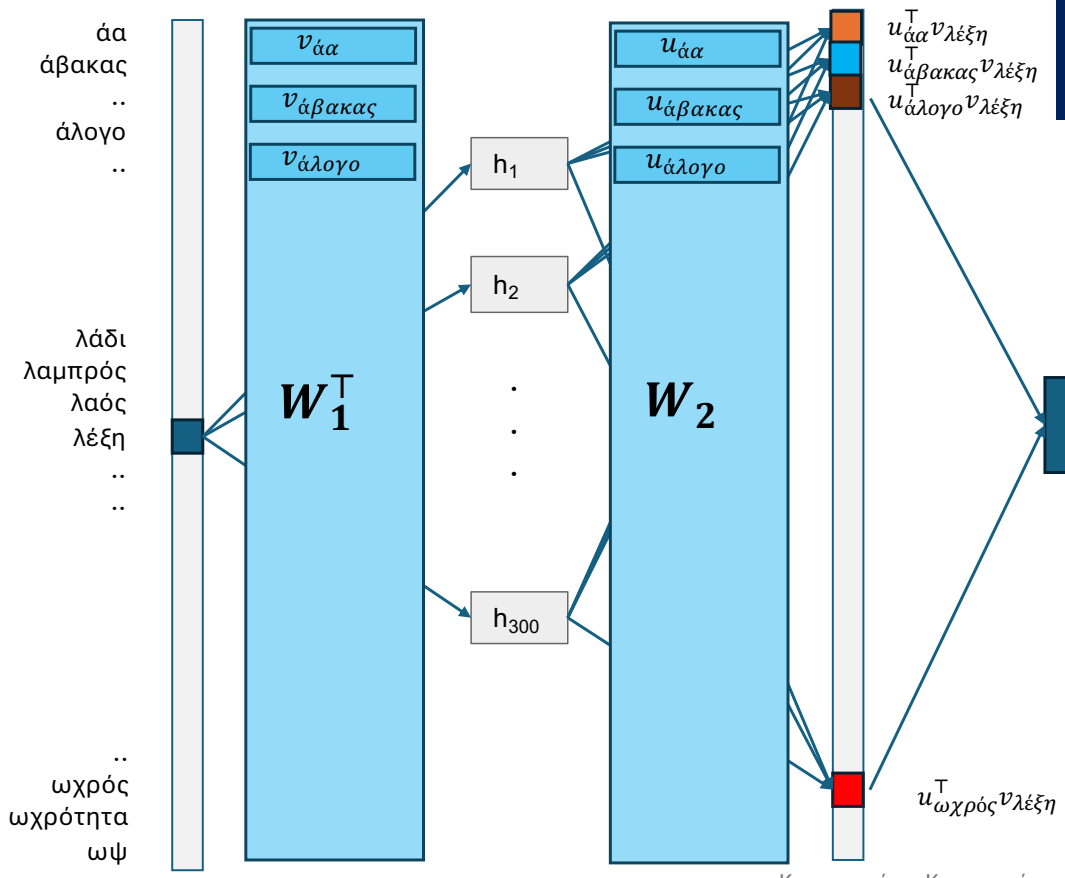

softmax

$$\frac{\exp(u_\alpha^T v_\beta)}{\sum_{\alpha' \in A} \exp(u_{\alpha'} v_\beta)}$$

W_1, W_2: παράμετροι του νευρωνικού δικτύου

Κωνσταντίνος Καραμανής

Νευρωνικό Δίκτυο για το Word2Vec

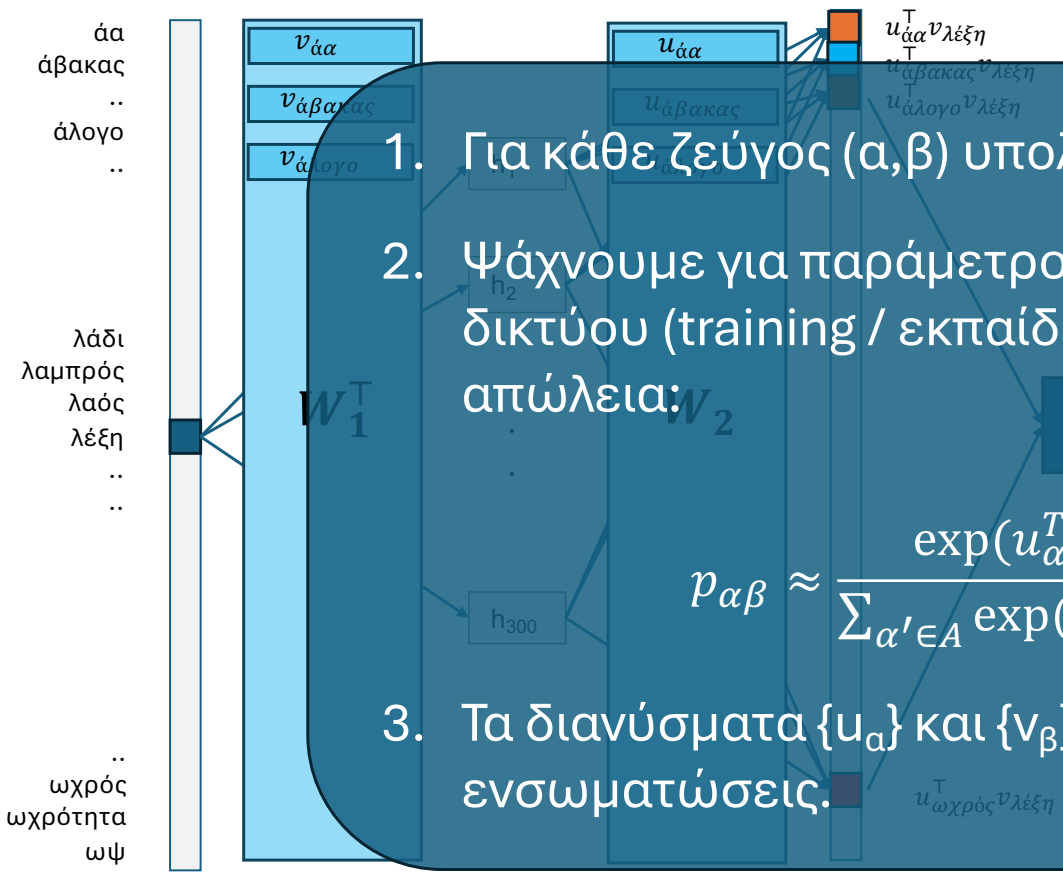

1. Για κάθε ζεύγος (α,β) υπολογίζουμε $p_{\alpha\beta}$ από το κείμενο
2. Ψάχνουμε για παράμετρους (W_1,W_2) του νευρωνικού δικτύου (training / εκπαίδευση) που ελαχιστοποιούν την απώλεια:

$$p_{\alpha\beta} \approx \frac{\exp(u_\alpha^T v_\beta)}{\sum_{\alpha' \in A} \exp(u_{\alpha'} v_\beta)}$$

W1, W2: παράμετροι του νευρωνικού δικτύου

3. Τα διανύσματα {u_α} και {v_β} είναι σημασιολογικές ενσωματώσεις.

Word2Vec: Πώς Γίνονται οι Υπολογισμοί

{ άα
άβακας
..
άλογο
..

λάδι
λαμπρός
λαός
λέξη
..
..

..
ωχρός
ωχρότητα
ωψ }

Word2Vec: Πώς Γίνονται οι Υπολογισμοί

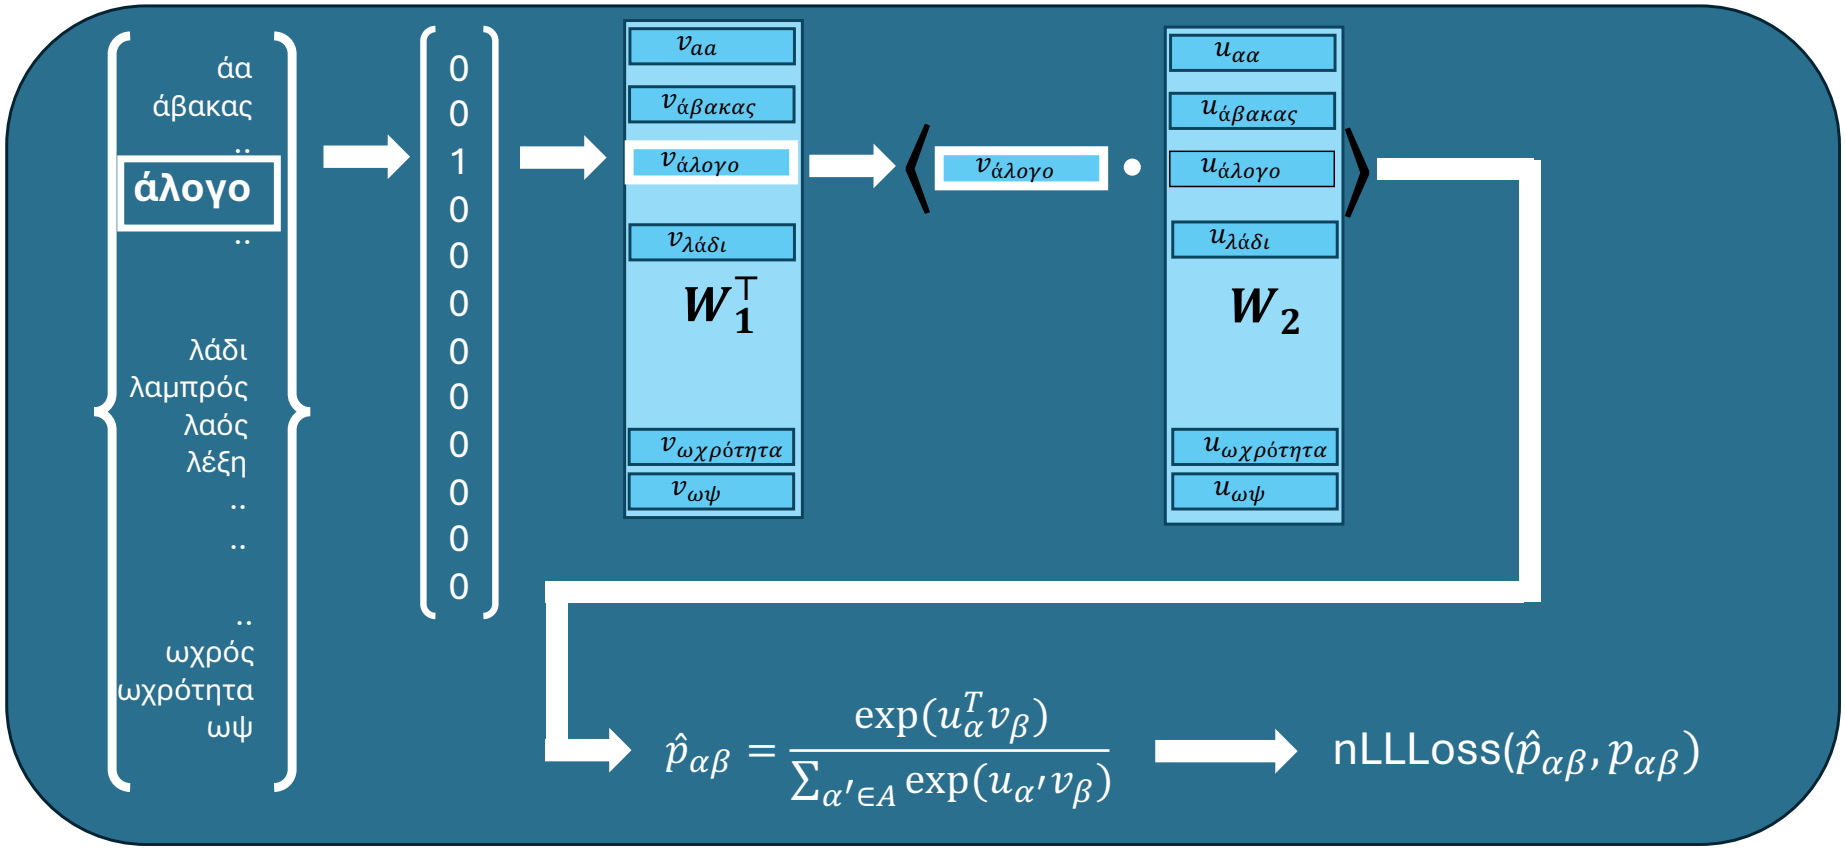

Word2Vec: Πώς Γίνονται οι Υπολογισμοί

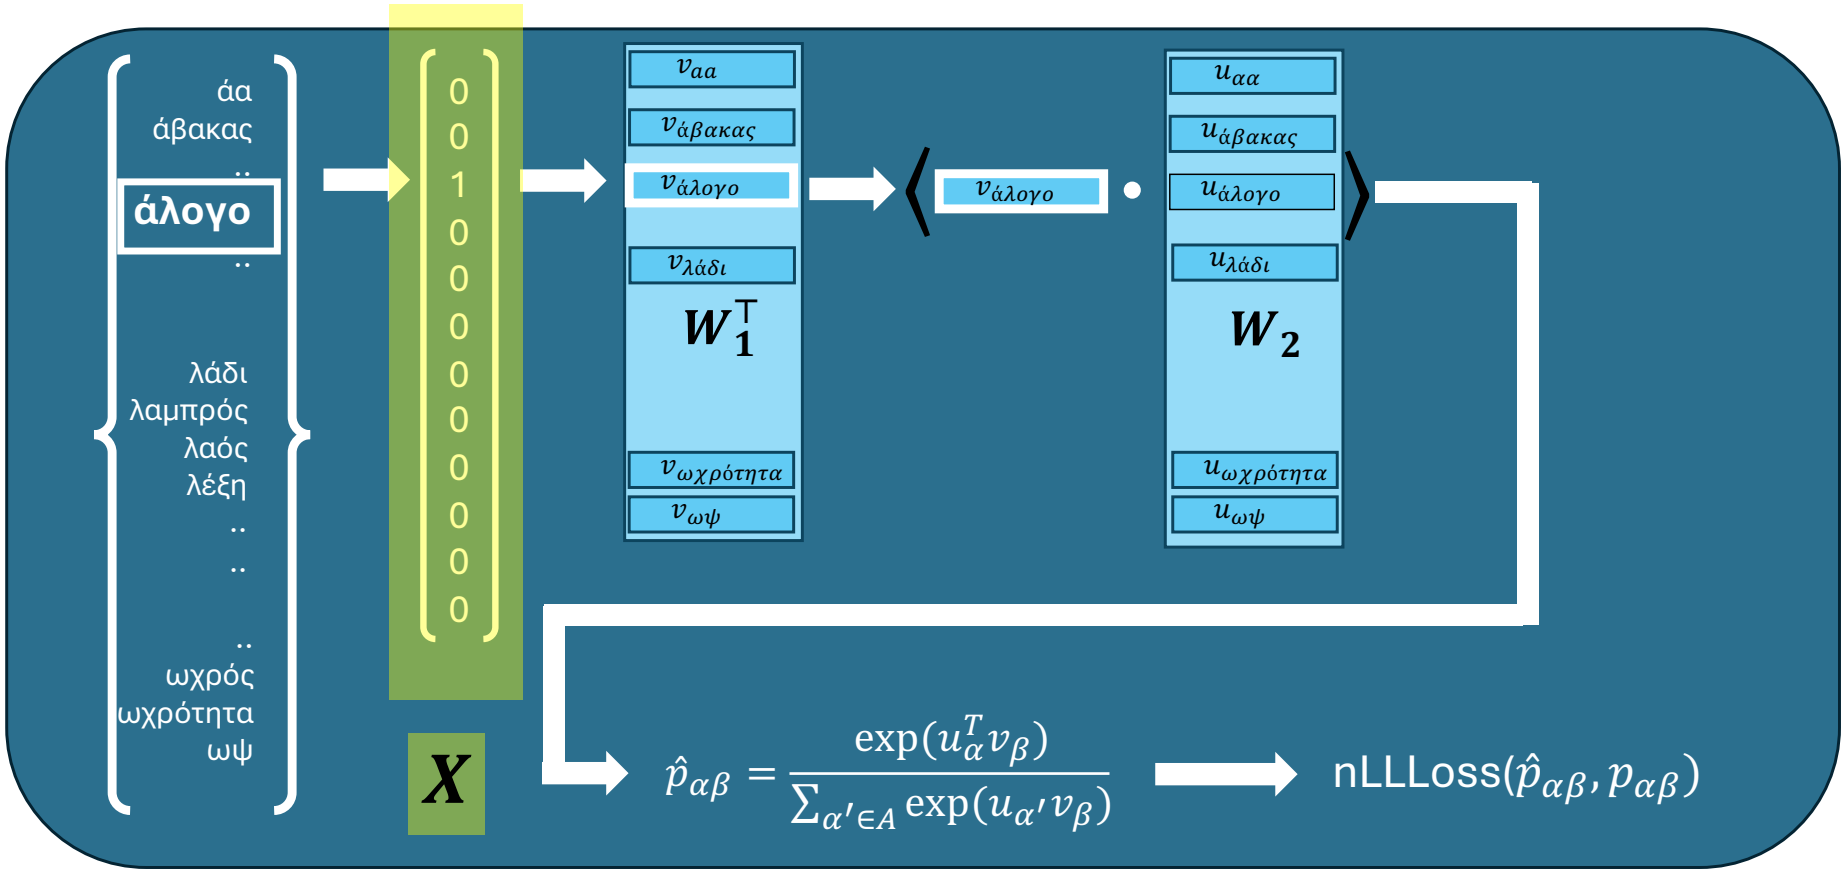

Word2Vec: Πώς Γίνονται οι Υπολογισμοί

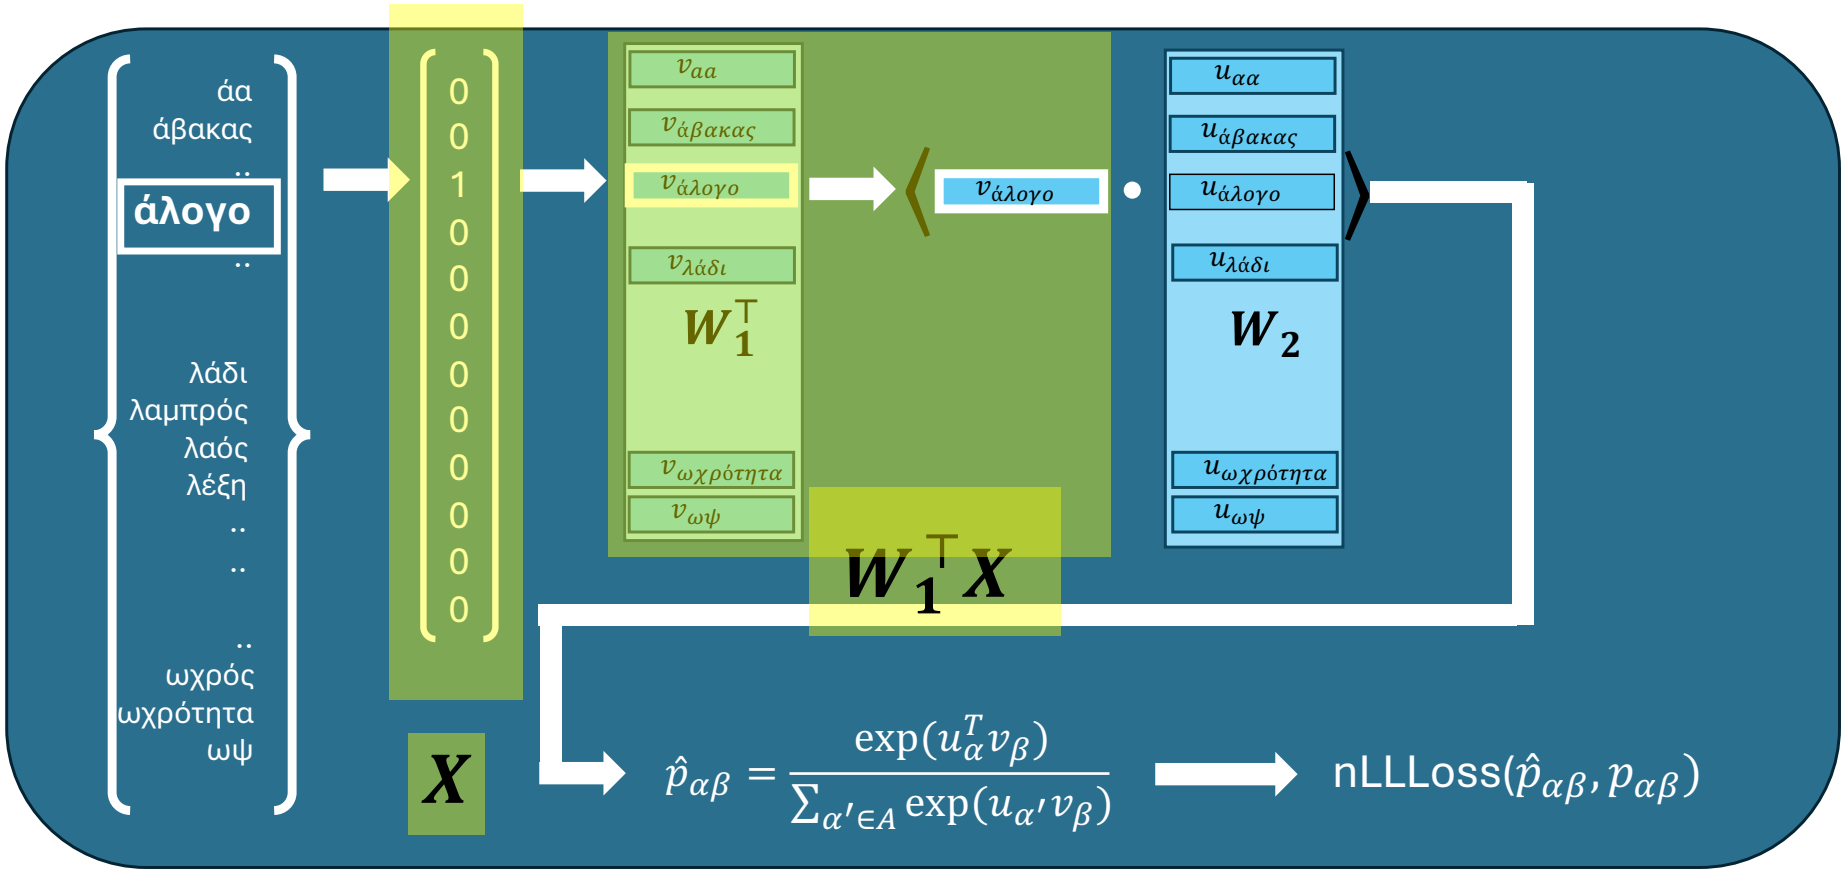

Word2Vec: Πώς Γίνονται οι Υπολογισμοί

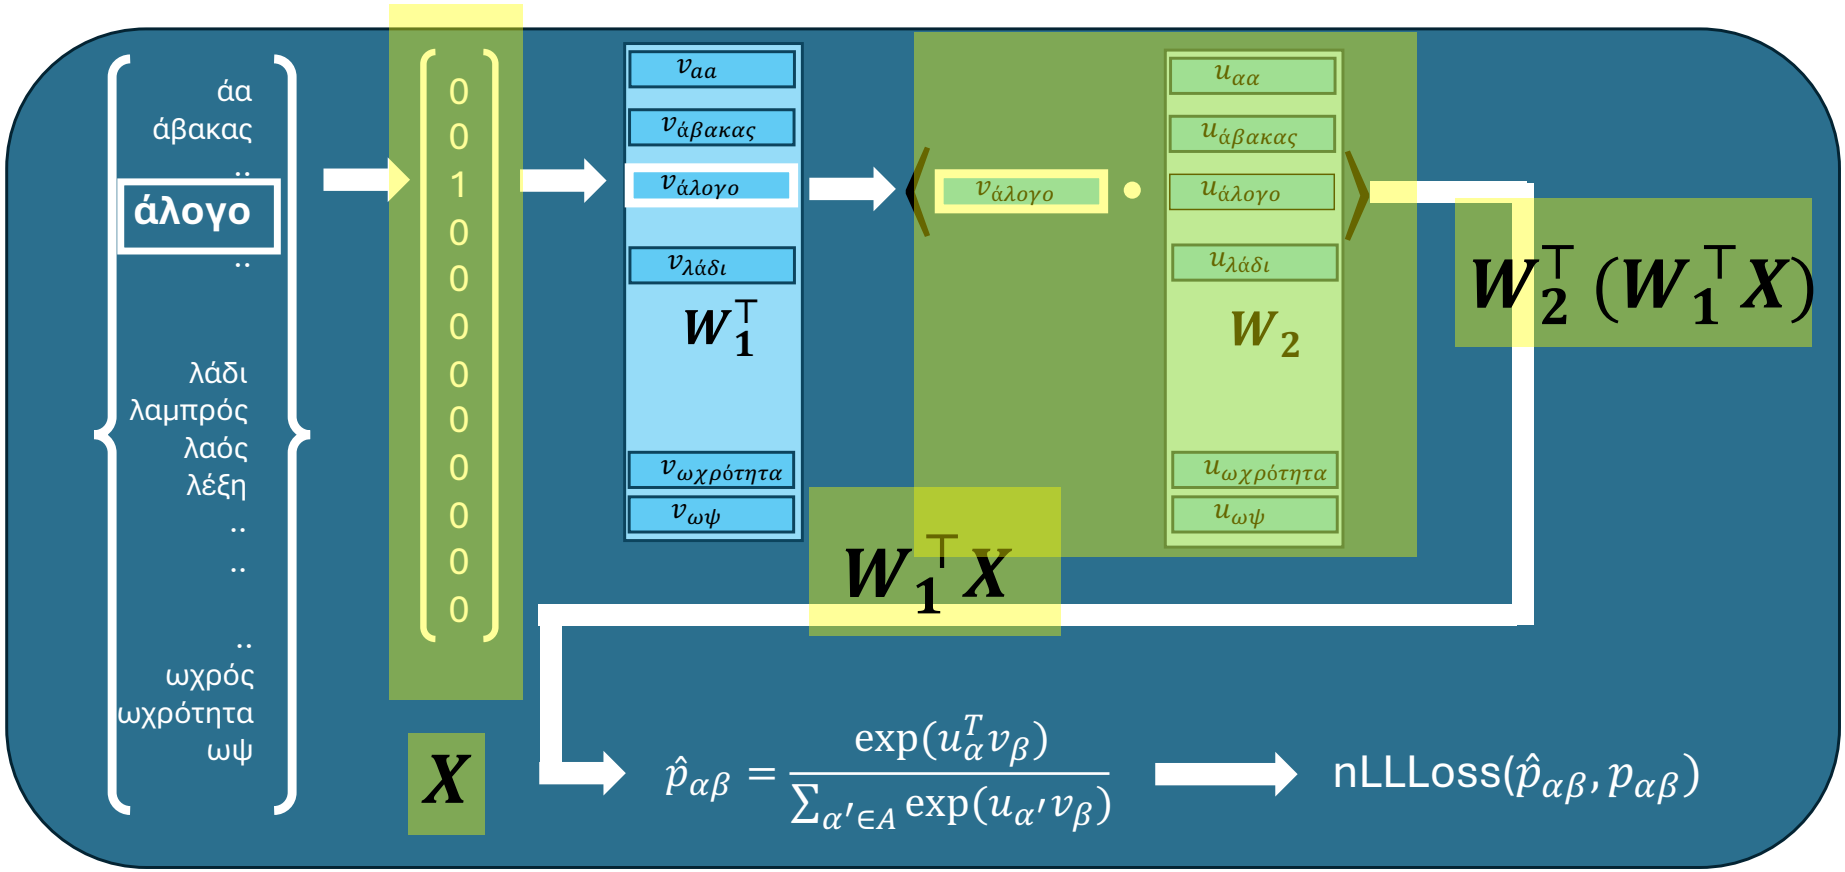

Word2Vec: Πώς Γίνονται οι Υπολογισμοί

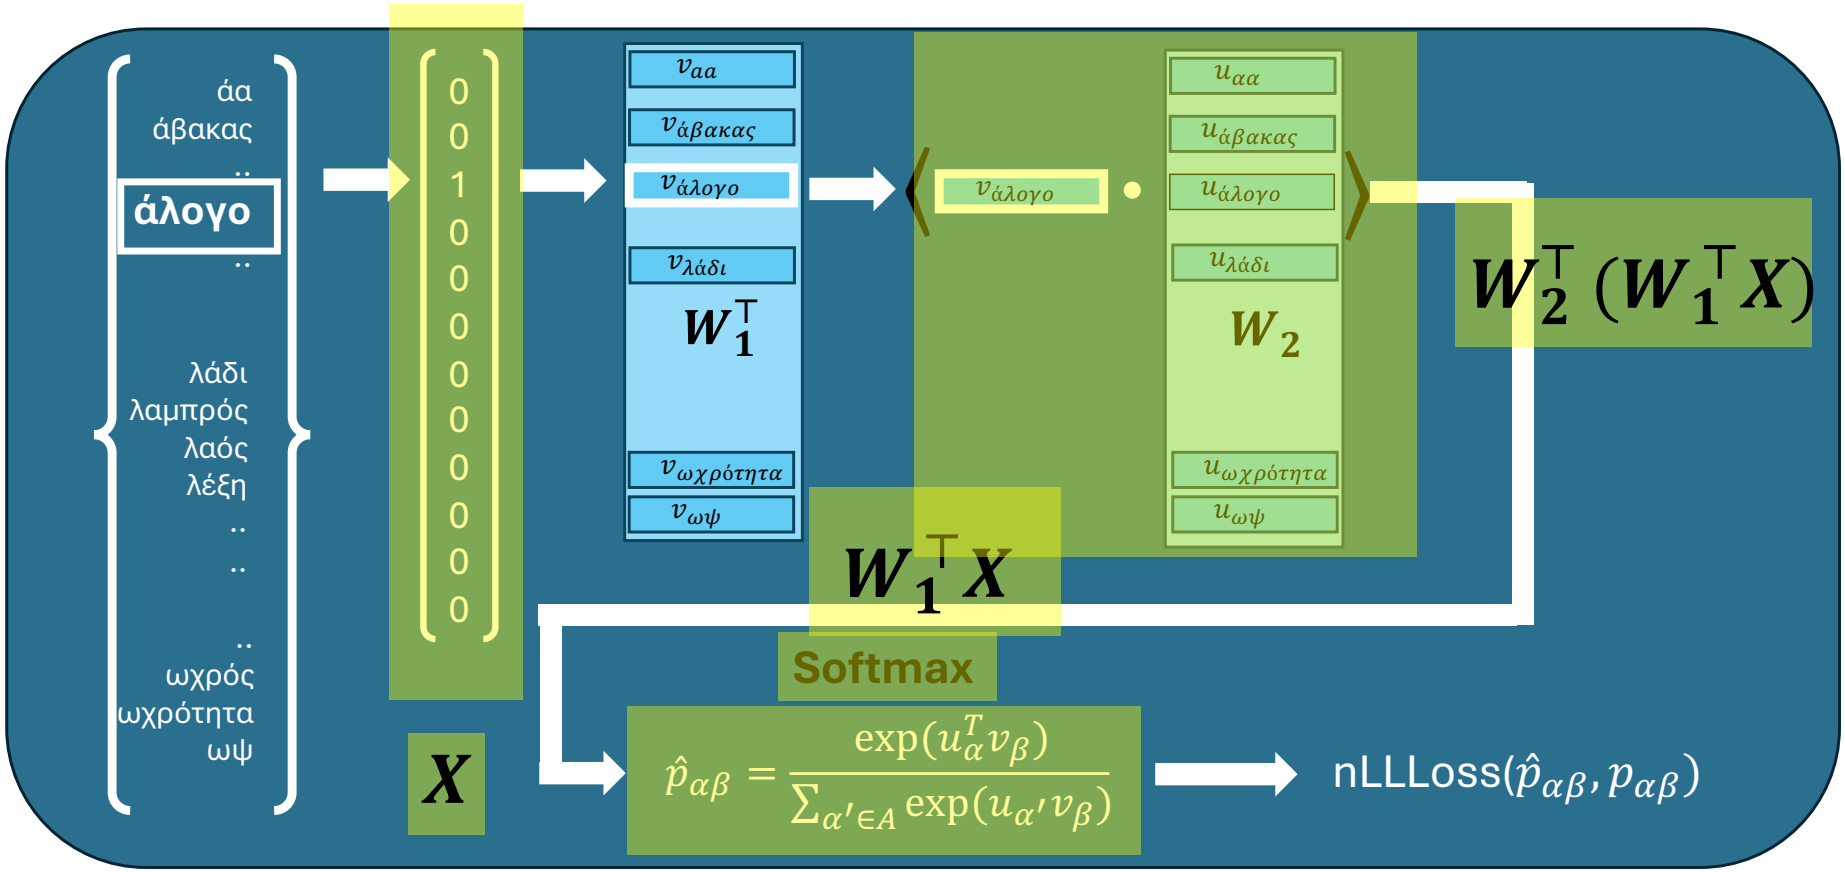

Word2Vec: Πώς Γίνονται οι Υπολογισμοί

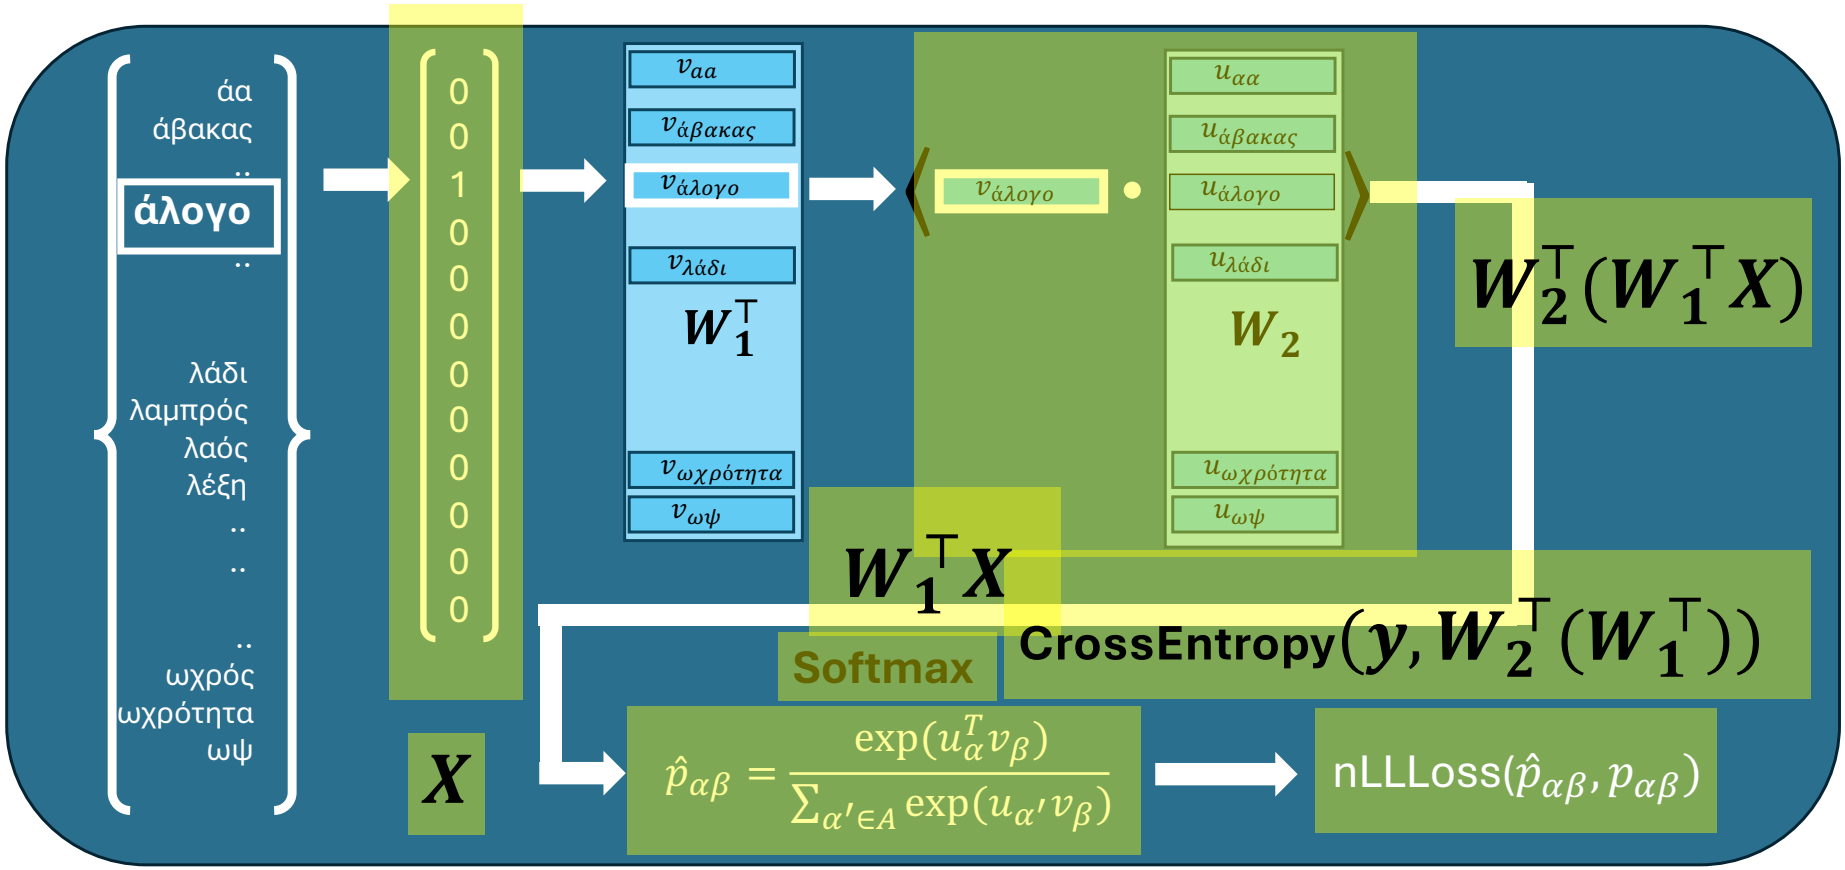

Word2Vec: Πώς Γίνονται οι Υπολογισμοί

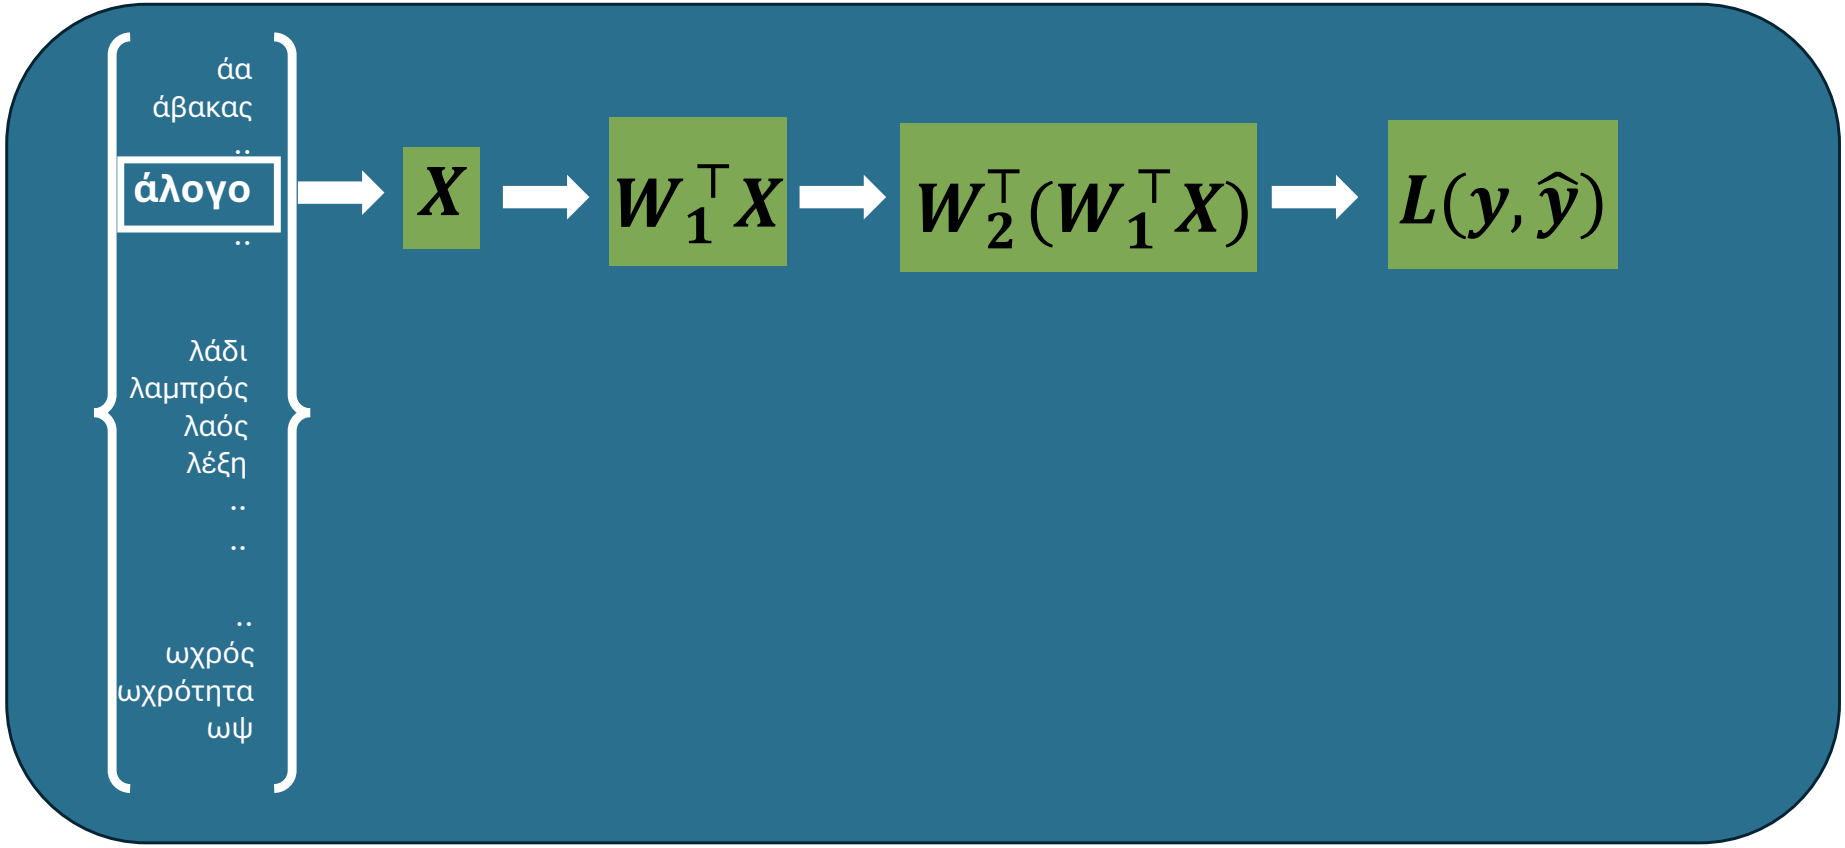

Word2Vec: Πώς Γίνονται οι Υπολογισμοί

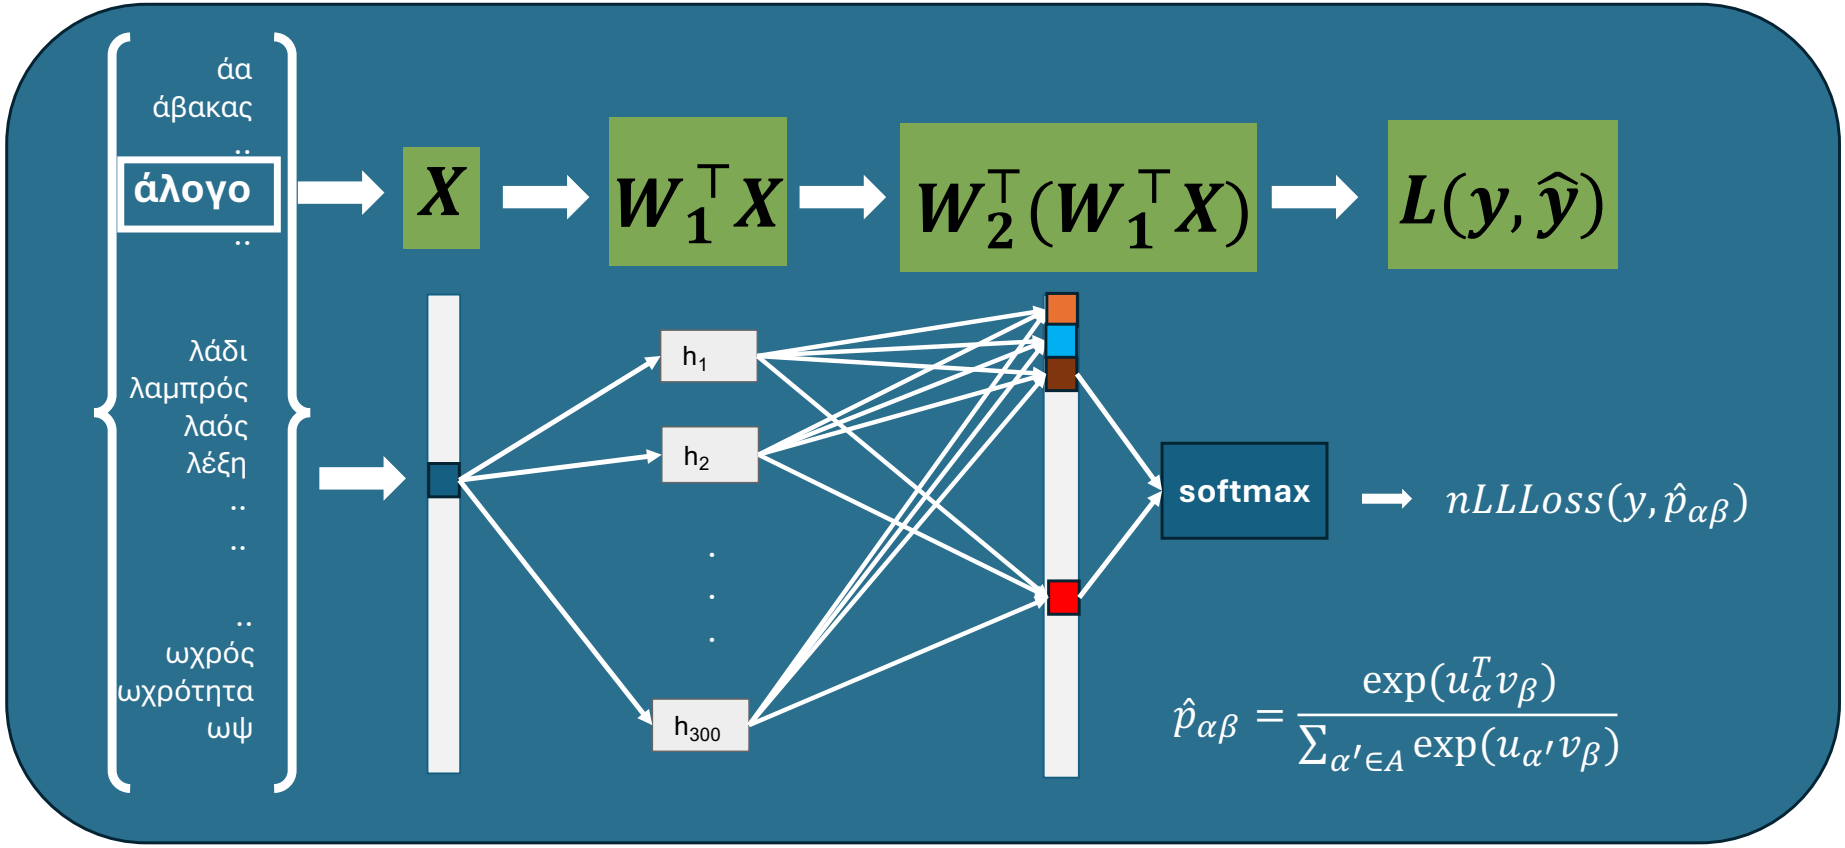

Word2Vec: Πώς Γίνονται οι Υπολογισμοί

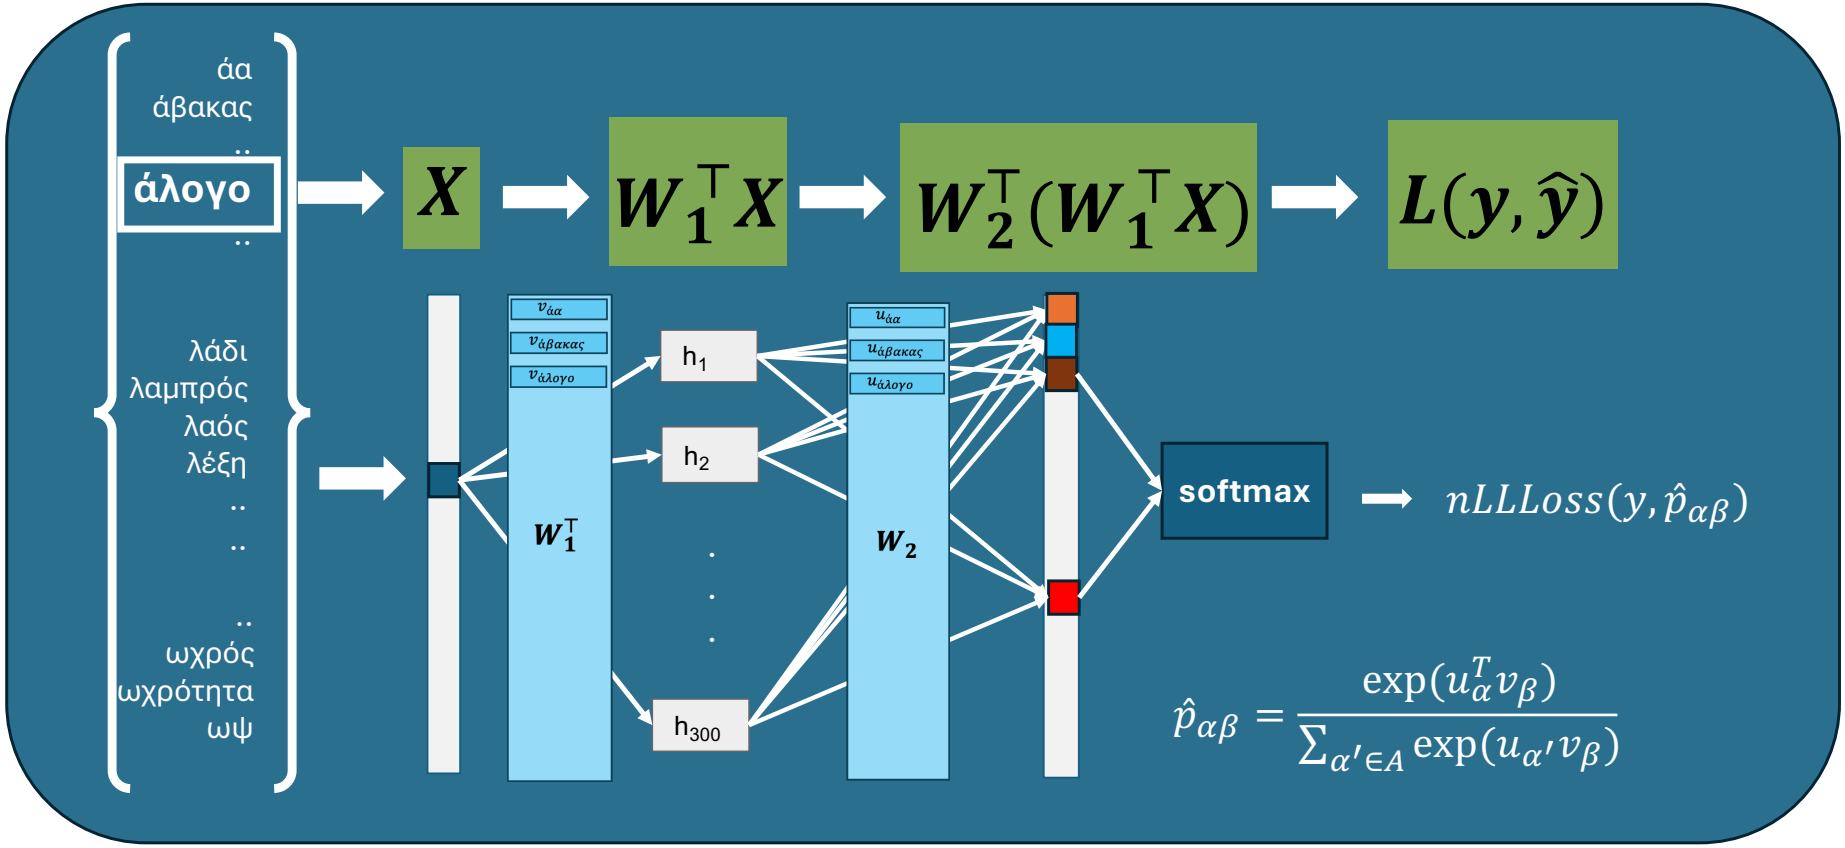

Word2Vec: Demo

```python
# Test word embedding
vector = model["king"]  # Get embedding for "king"
print("Vector size:", len(vector))
```

```
Vector size: 300
```

Word2Vec: Demo

```python
# Test word embedding
vector = model["king"]  # Get embedding for "king"
print("Vector size:", len(vector))
```

```
Vector size: 300
```

```python
# Find most similar words to "Parthenon"
for word in model.most_similar("Parthenon"):
  print(word)
```

```
('Acropolis', 0.5453481674194336)
('metopes', 0.5171760320663452)
('Parthenon_temple', 0.5158255100250244)
('Propylaea', 0.5151312351226807)
('Elgin_marbles', 0.4917999804019928)
('friezes', 0.4915829598903656)
('ancient_Athenian', 0.4904763996601105)
('Pergamon', 0.48820197582244873)
('Elgin_Marbles', 0.4869332015514374)
('Acropolis_hill', 0.484723836183548)
```

Word2Vec: Demo

```python
# Test word embedding
vector = model["king"]  # Get embedding for "king"
print("Vector size:", len(vector))
```

```
Vector size: 300
```

```python
# Find most similar words to "Parthenon"
for word in model.most_similar("Parthenon"):
  print(word)
```

```
('Acropolis', 0.5453481674194336)
('metopes', 0.5171760320663452)
('Parthenon_temple', 0.5158255100250244)
('Propylaea', 0.5151312351226807)
('Elgin_marbles', 0.4917999804019928)
('friezes', 0.4915829598903656)
('ancient_Athenian', 0.4904763996601105)
('Pergamon', 0.48820197582244873)
('Elgin_Marbles', 0.4869332015514374)
('Acropolis_hill', 0.484723836183548)
```

Συνημίτονο της γωνίας: $\angle \boldsymbol{u}_{acropolis} \boldsymbol{u}_{parthenon}$

Μεγαλύτερο συνημίτονο → μικρότερη γωνία
→ Πιο κοντά οι ενσωματώσεις

Word2Vec: οι βασικές ιδέες

Σημασιολογικές ενσωματώσεις λέξεων

Self-supervision: αξιοποιούμε μια σχεδόν ανεξάντλητη πηγή -- το κείμενο στο διαδίκτυο
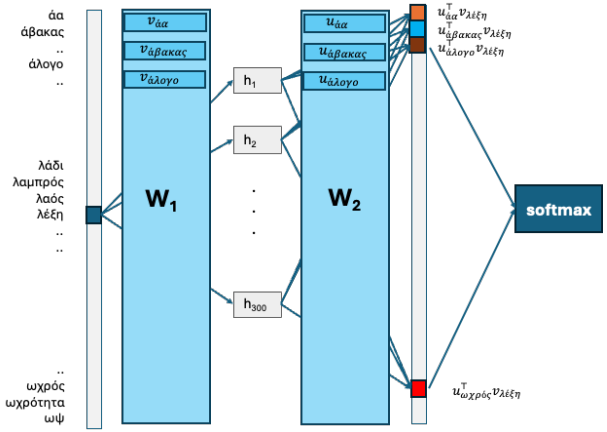
Εκπαιδεύουμε ένα νευρωνικό δίκτυο που μας δίνει τις σημασιολογικές ενσωματώσεις κάθε λέξης