Παραγωγική Τεχνητή Νοημοσύνη: Generative AI

Κωνσταντίνος Καραμανής

The University of Texas at Austin & Archimedes/Athena RC

constantine@utexas.edu

https://caramanis.github.io/

Ας θυμηθούμε τα προηγούμενα...

Search (αναζήτηση) σε βάση γνώσεων

Επιστημονικά περιοδικά που περιέχουν χιλιάδες δημοσιευμένα άρθρα για παθήσεις του ανοσοποιητικού συστήματος

Ερώτημα χρήστη (query): «Ποιες είναι οι χρήσεις και πιθανές παρενέργειες του IL-23 inhibitor biologic Skyrizi;»

Η «σωστή» απάντηση;

Recall@K NDCG@K

Search (αναζήτηση) σε βάση γνώσεων

Επιστημονικά περιοδικά που περιέχουν χιλιάδες δημοσιευμένα άρθρα για παθήσεις του ανοσοποιητικού συστήματος

Ερώτημα χρήστη (query): «Ποιες είναι οι χρήσεις και πιθανές παρενέργειες του IL-23 inhibitor biologic Skyrizi;»

Πώς εκτιμούμε ποια είναι τα σχετικά άρθρα στη βάση γνώσεων;

Η «σωστή» απάντηση;

Recall@K NDCG@K

1. Bag of Words
2. TF-IDF/BM25
3. **Semantic Search**

Αναζήτηση σε Βάση Γνώσεων

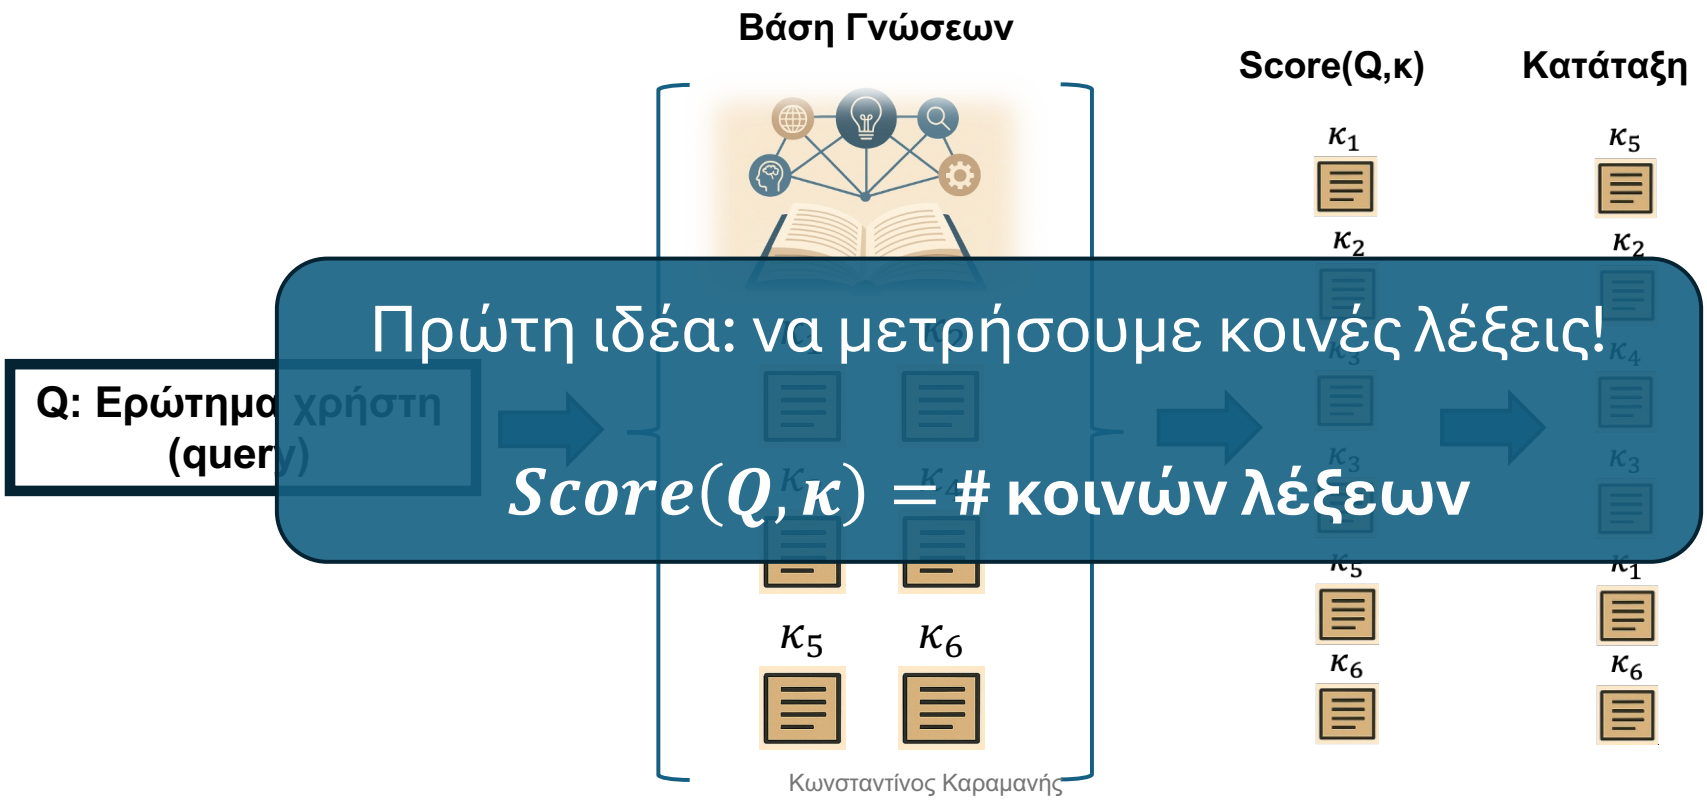

Πρώτη ιδέα: να μετρήσουμε κοινές λέξεις!

$$Score(Q, \kappa) = \#\ \text{κοινών λέξεων}$$

Αναζήτηση σε Βάση Γνώσεων

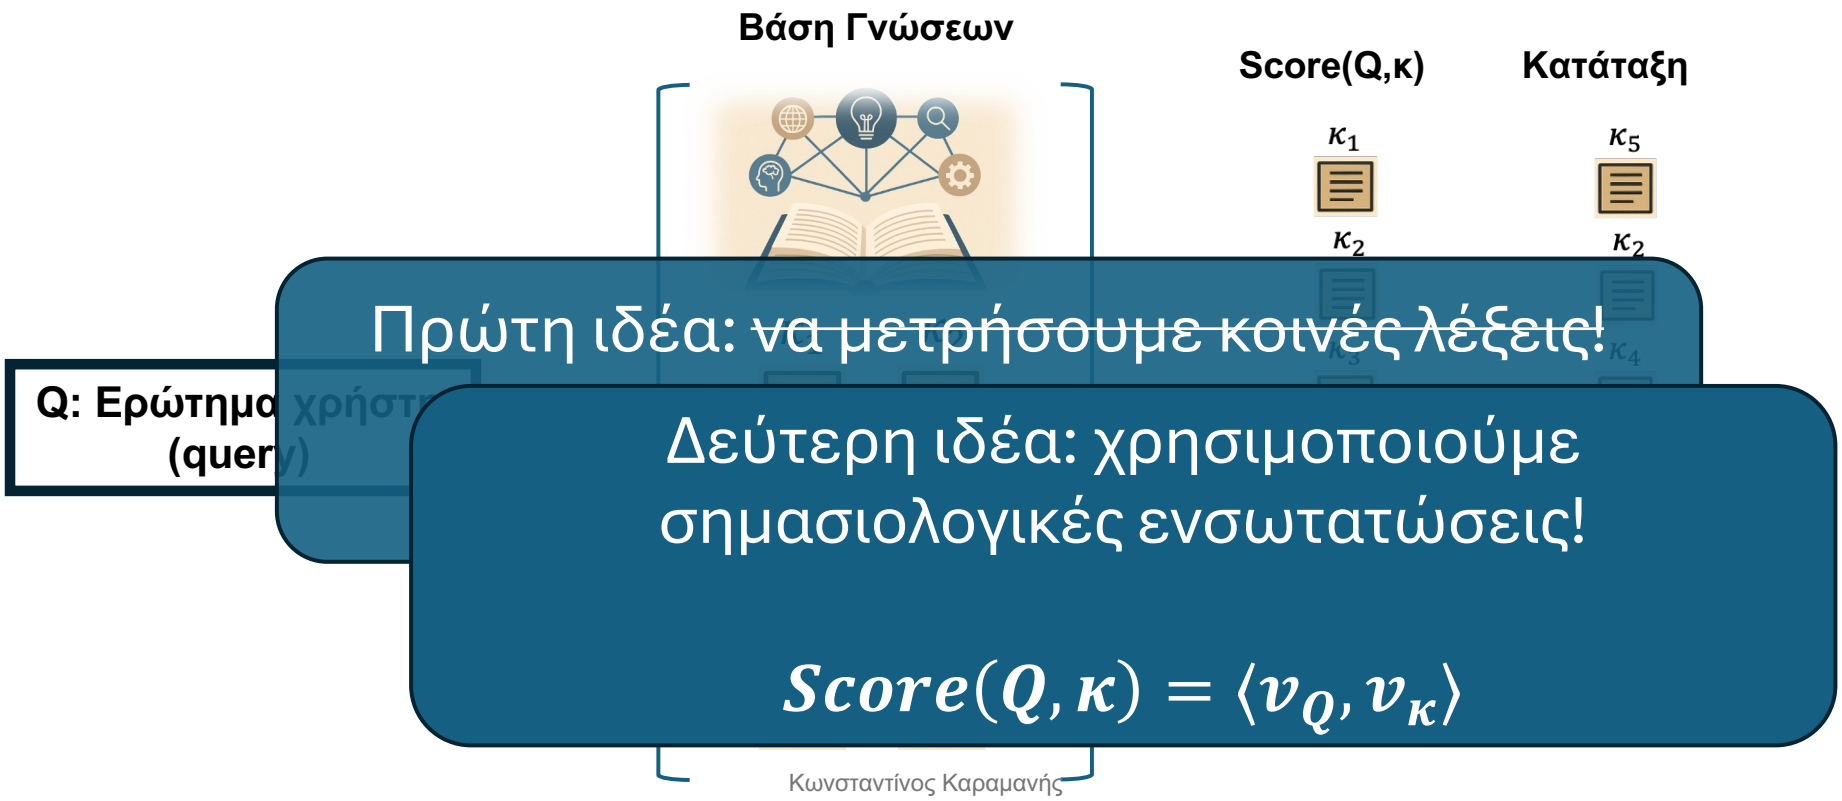

Πρώτη ιδέα: ~~να μετρήσουμε κοινές λέξεις!~~

Δεύτερη ιδέα: χρησιμοποιούμε σημασιολογικές ενσωματώσεις!

$$Score(Q, \kappa) = \langle v_Q, v_\kappa \rangle$$

Αναζήτηση σε Βάση Γνώσεων

Σημασιολογικές ενσωματώσεις

Query: Q → v_Q

κείμενα

κ_1 κ_2 κ_3 κ_4 κ_5 κ_6

→

v_{κ_1}
v_{κ_2}
v_{κ_3}
v_{κ_4}
v_{κ_5}
v_{κ_6}

Κατατάσσουμε τα κείμενα σε φθίνουσα σειρά εσωτερικού γινομένου

$$\langle v_\kappa, v_Q \rangle$$

Αναζήτηση σε Βάση Γνώσεων

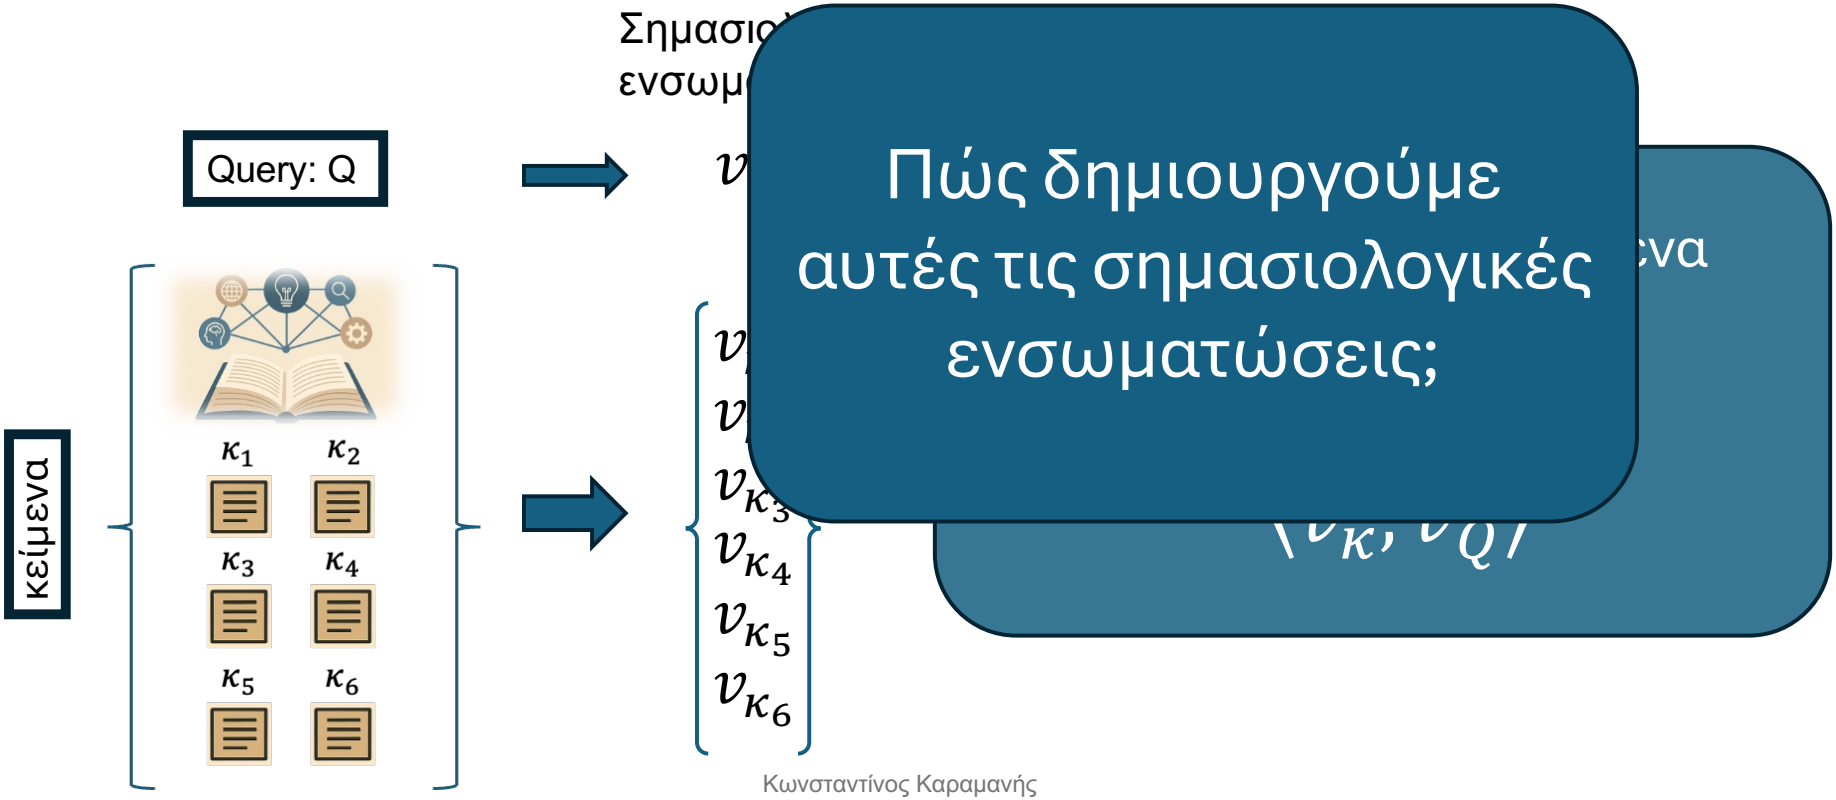

Πώς δημιουργούμε αυτές τις σημασιολογικές ενσωματώσεις;

Αναζήτηση σε Βάση Γνώσεων

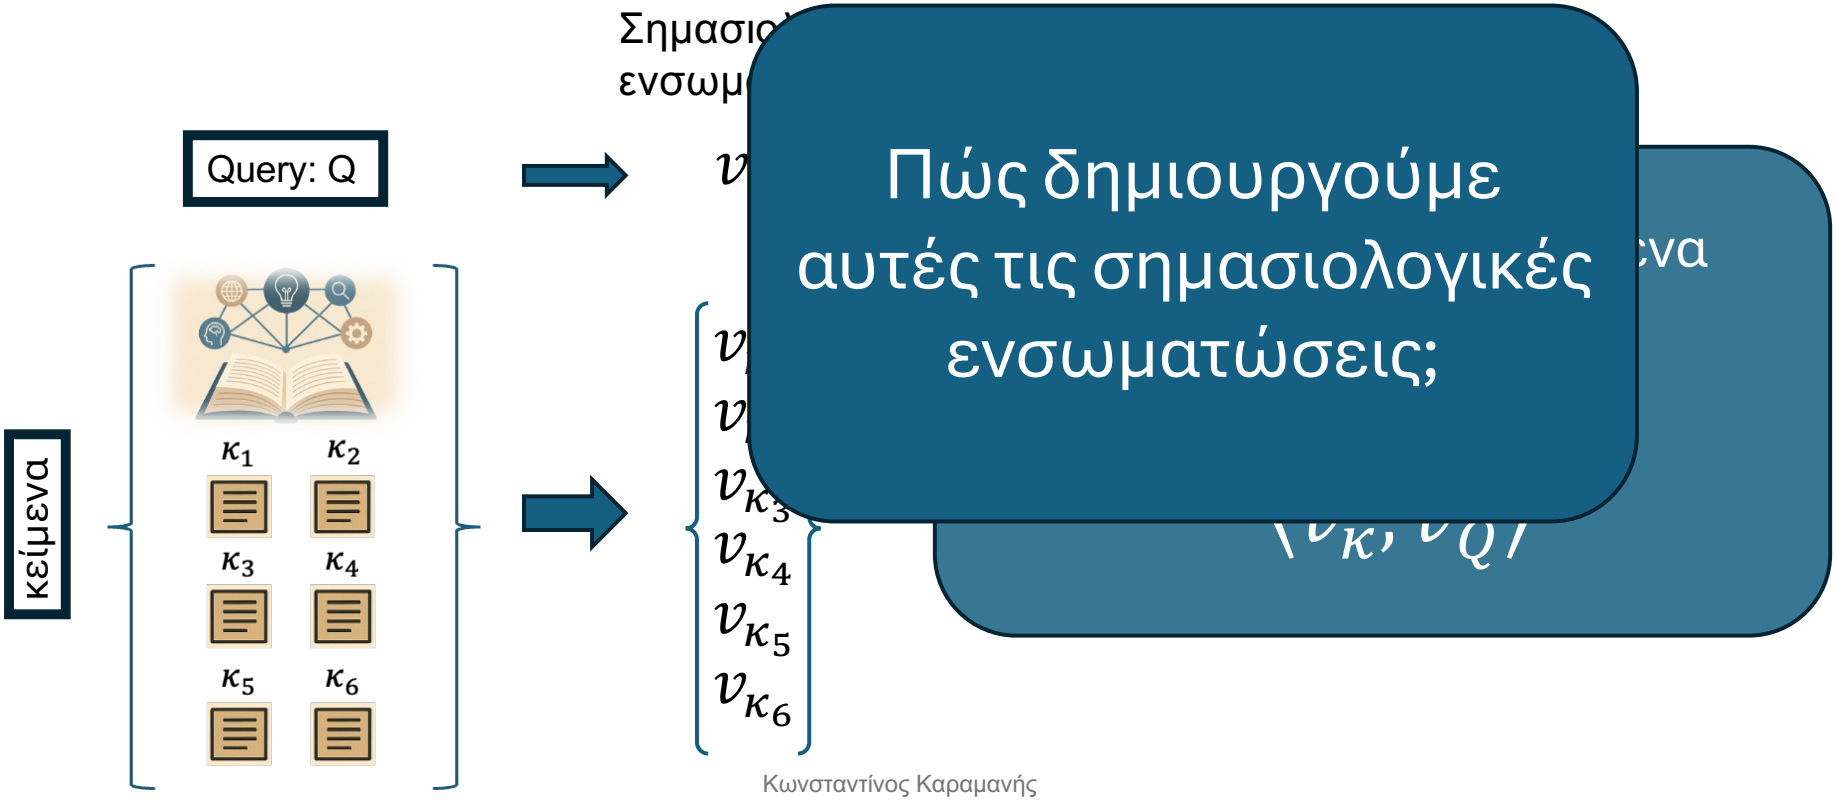

Πώς δημιουργούμε αυτές τις σημασιολογικές ενσωματώσεις;

Σημασιολογικές Ενσωματώσεις Κειμένου

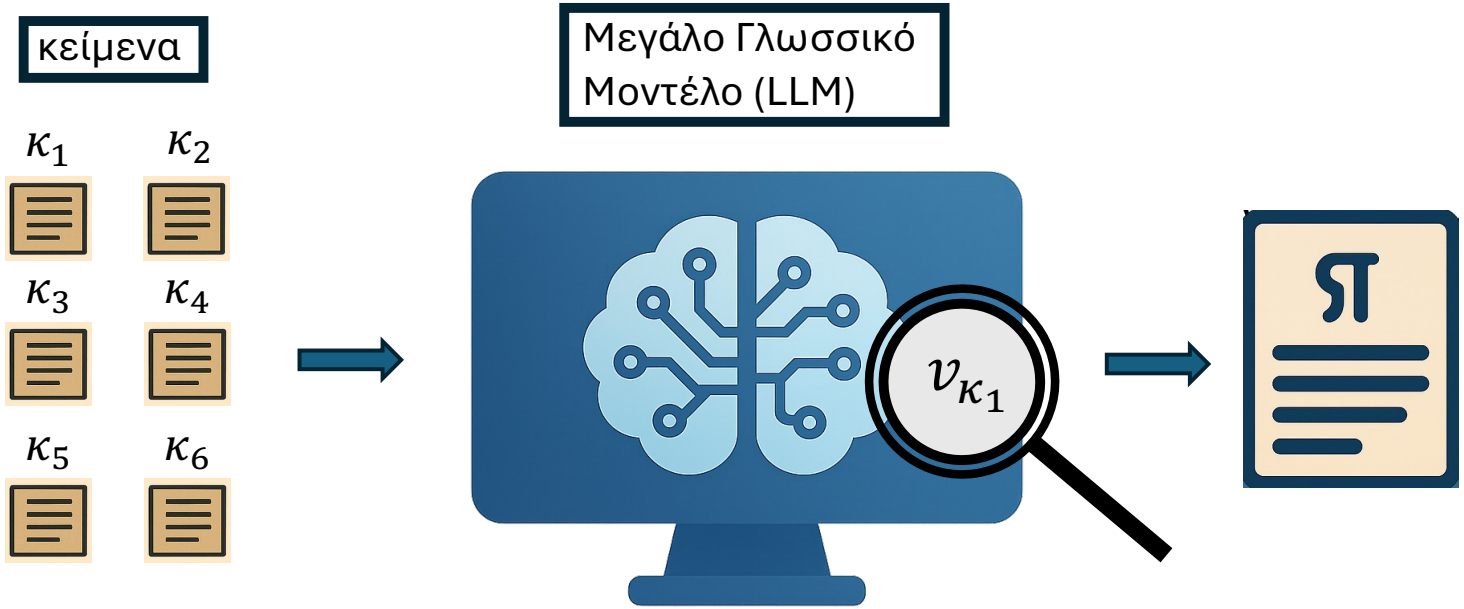

Σημασιολογικές Ενσωματώσεις Κειμένου

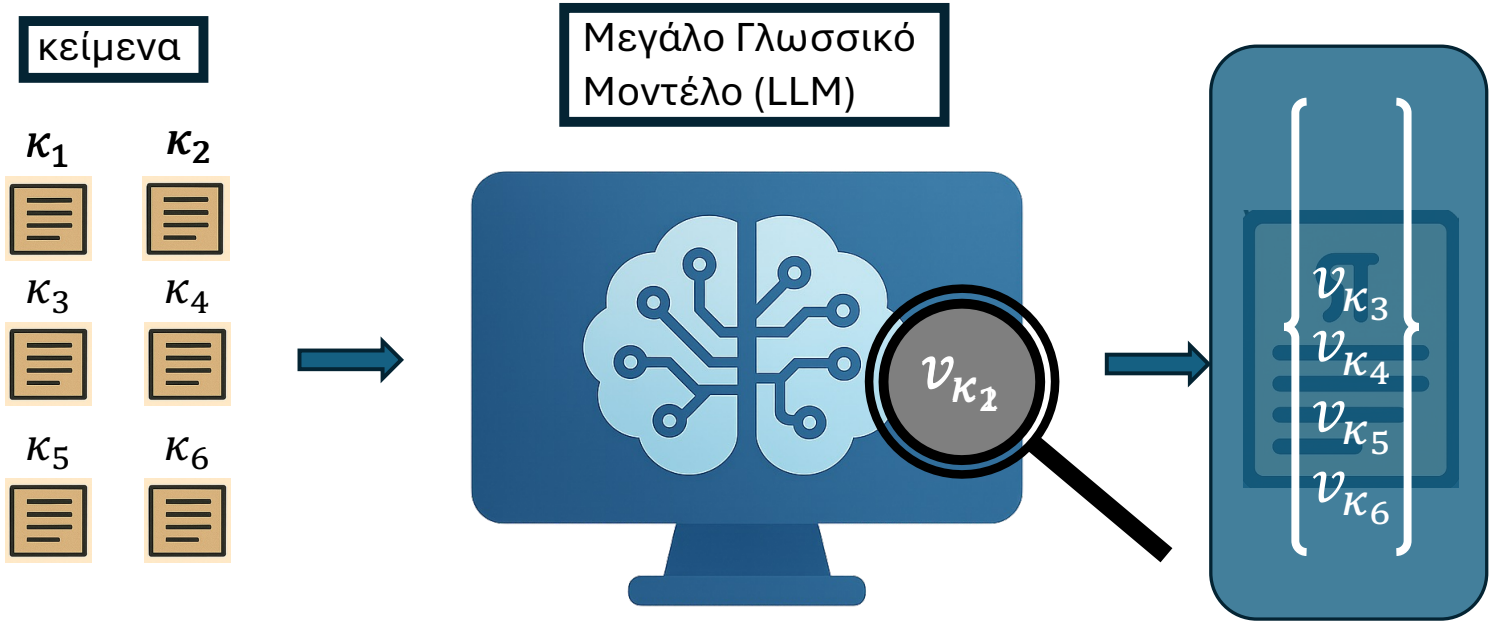

Σημασιολογικές Ενσωματώσεις Κειμένου

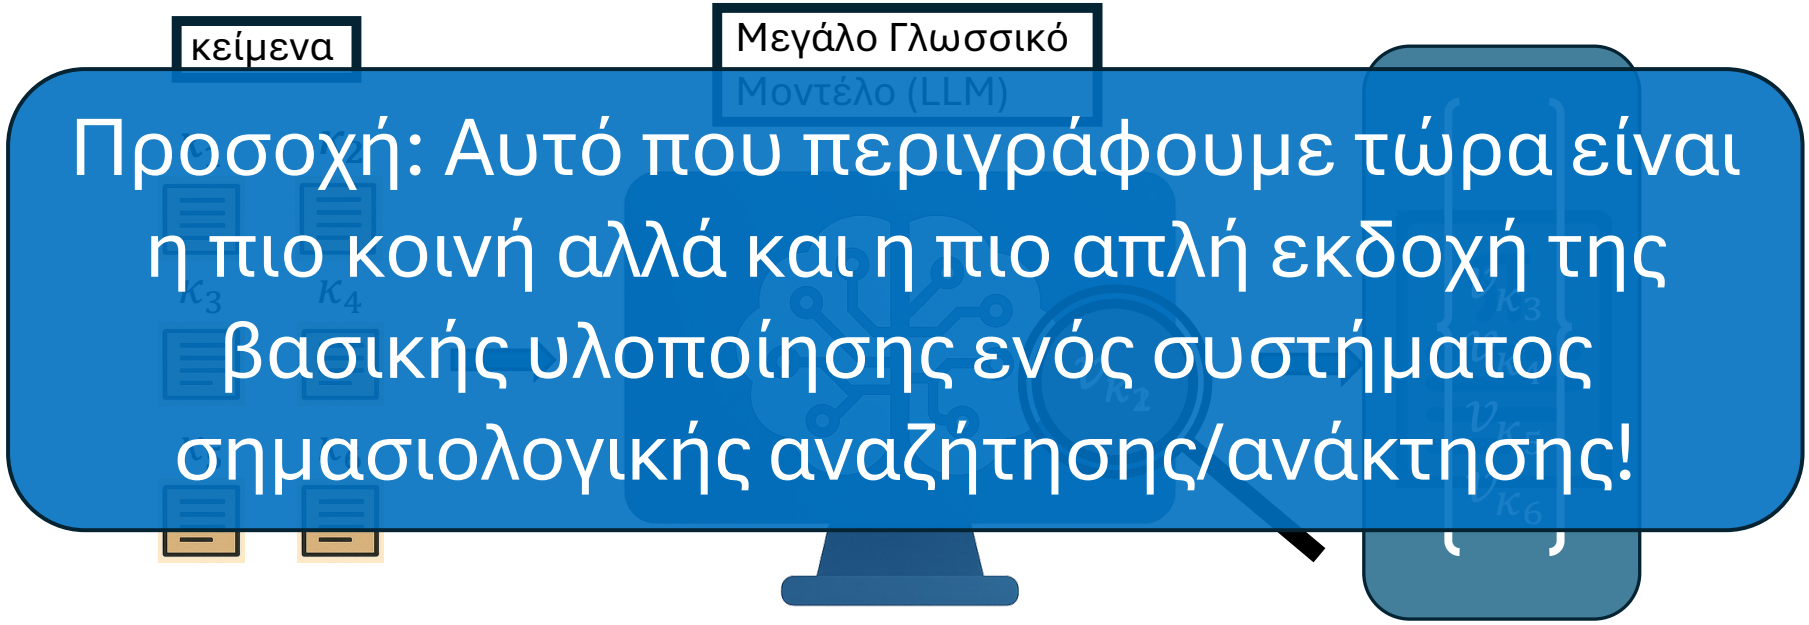

Προσοχή: Αυτό που περιγράφουμε τώρα είναι η πιο κοινή αλλά και η πιο απλή εκδοχή της βασικής υλοποίησης ενός συστήματος σημασιολογικής αναζήτησης/ανάκτησης!

Σημασιολογικές Ενσωματώσεις Κειμένου

1. Μετατρέπουμε την Βάση Γνώσης μας σε συλλογή μικρότερων κειμένων, 300-500 λέξεων: τμηματοποίηση ή chunking

Π: {πλήρες κείμενο διαλέξεων} $\Longrightarrow$ {κομμάτια κειμένου}

2. Περνάμε τα κομμάτια $\{\boldsymbol{\kappa_i}\}$ από ένα LLM: υπολογίζουμε ενσωματώσεις $\{\boldsymbol{v_i}\}$

3. Με “query” Q, υπολογίζουμε την ενσωμάτωση $\boldsymbol{v_Q}$ και κατατάσσουμε τα κομμάτια $\{\boldsymbol{\kappa_i}\}$ σε φθίνουσα σειρά: $\langle \boldsymbol{v_Q}, \boldsymbol{v_i} \rangle$

RAG: Retrieval Augmented Generation

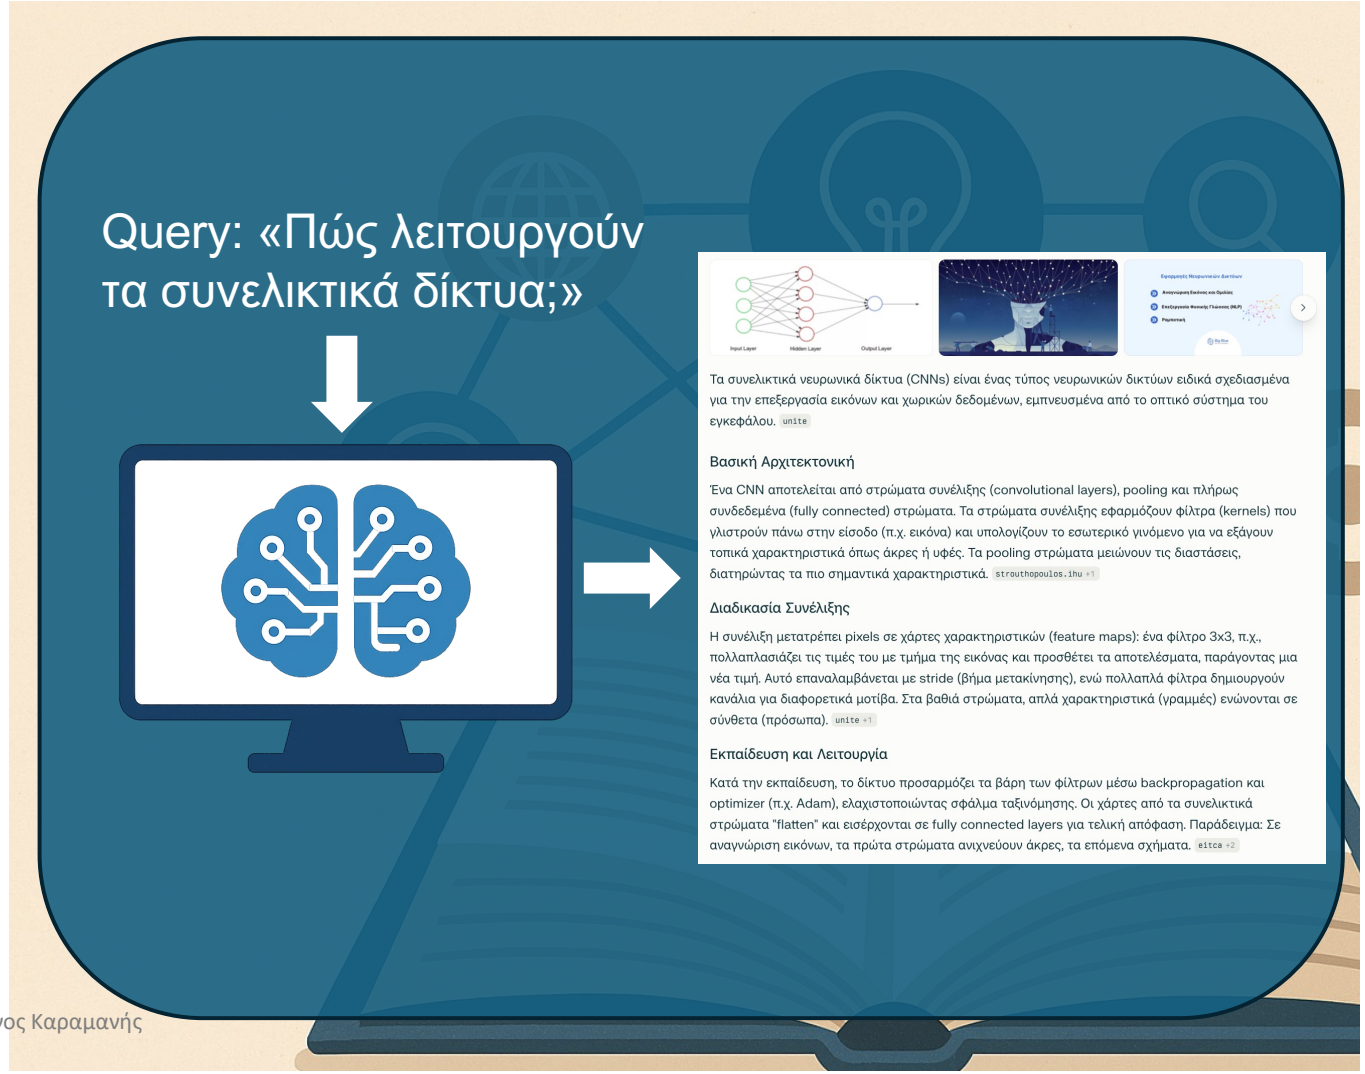

RAG: Retrieval Augmented Generation

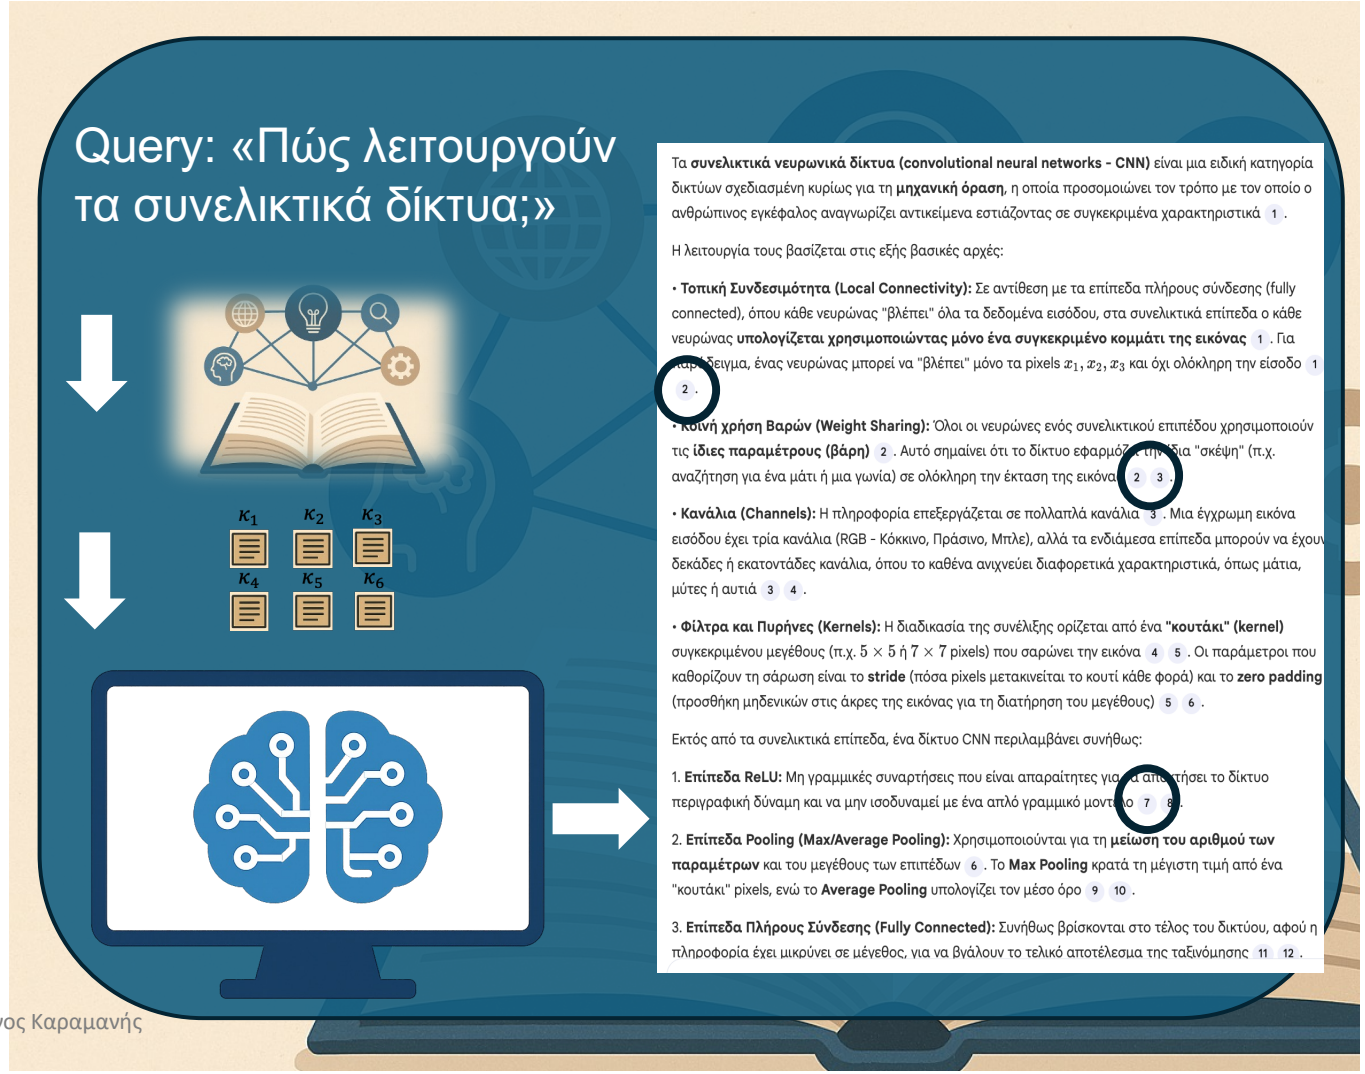

RAG: Retrieval Augmented Generation

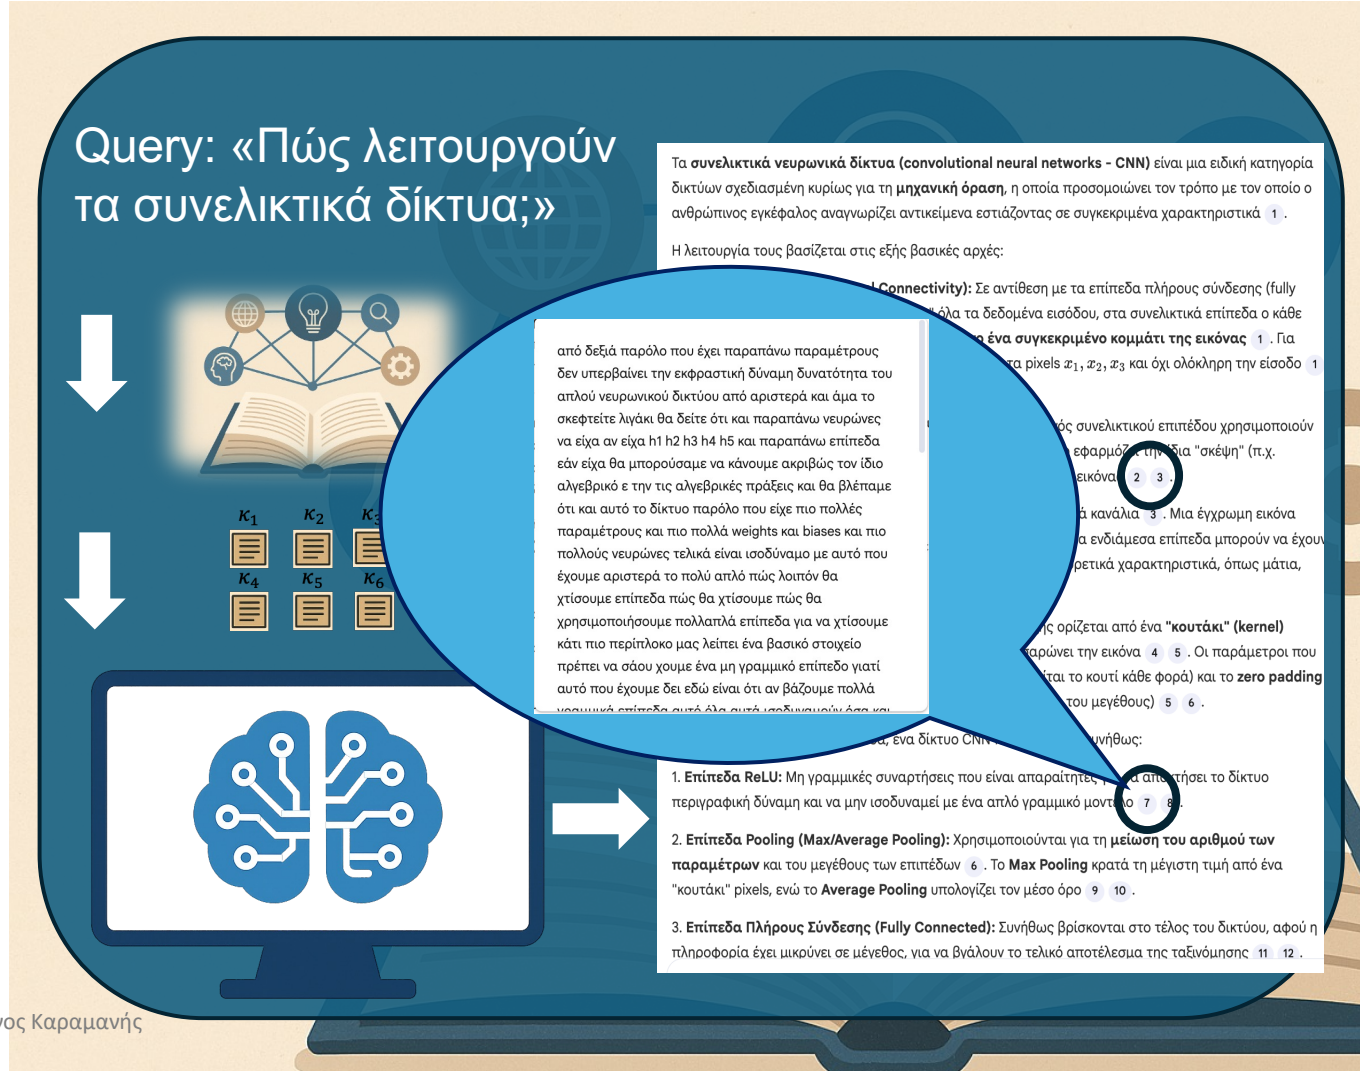

RAG: Retrieval Augmented Generation

Ο στόχος: Ένα σύστημα τεχνητής νοημοσύνης που απαντά σε ερωτήσεις του χρήστη με απαντήσεις βασισμένες σε μια δεδομένη βάση γνώσεων και, επιπλέον, τεκμηριωμένες με κείμενα από τη βάση γνώσεων.

Πλεονεκτήματα:

1. Παρέχει πρόσβαση σε ενημερωμένα ή εξειδικευμένα δεδομένα χωρίς επανεκπαίδευση του μοντέλου.
2. Βελτιώνει την ακρίβεια των απαντήσεων και περιορίζει τις «παραισθήσεις» (hallucinations) των μεγάλων γλωσσικών μοντέλων (LLMs)

1. Bag of Words
2. TF-IDF/BM25
3. Semantic Search

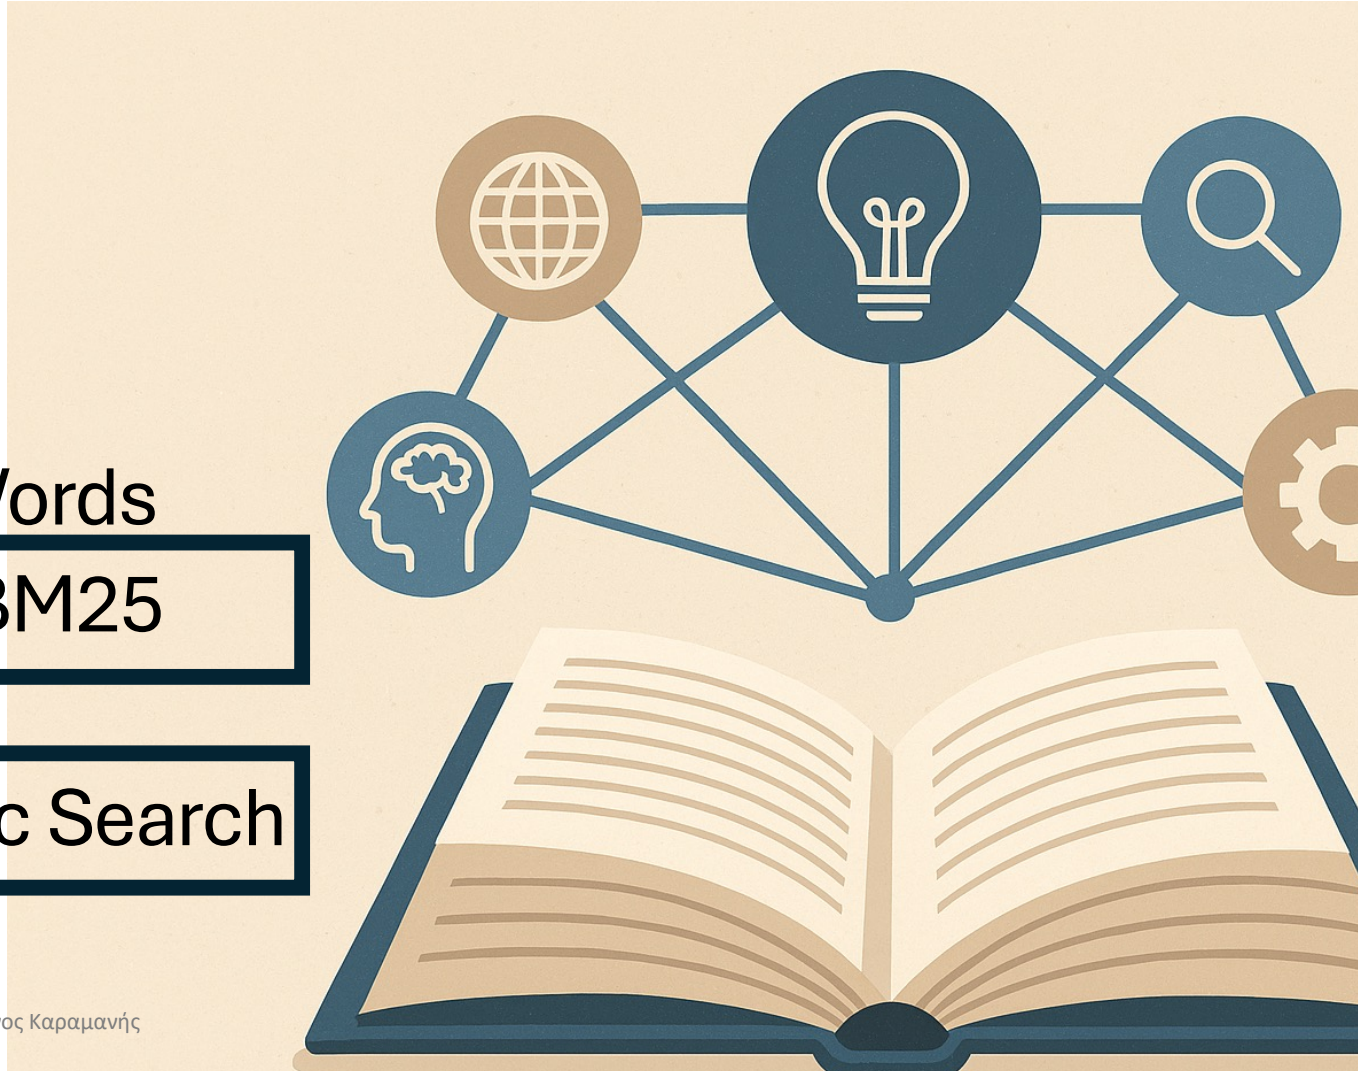

1. Bag of Wo
2. TF-IDF/BM
3. Semantic Search

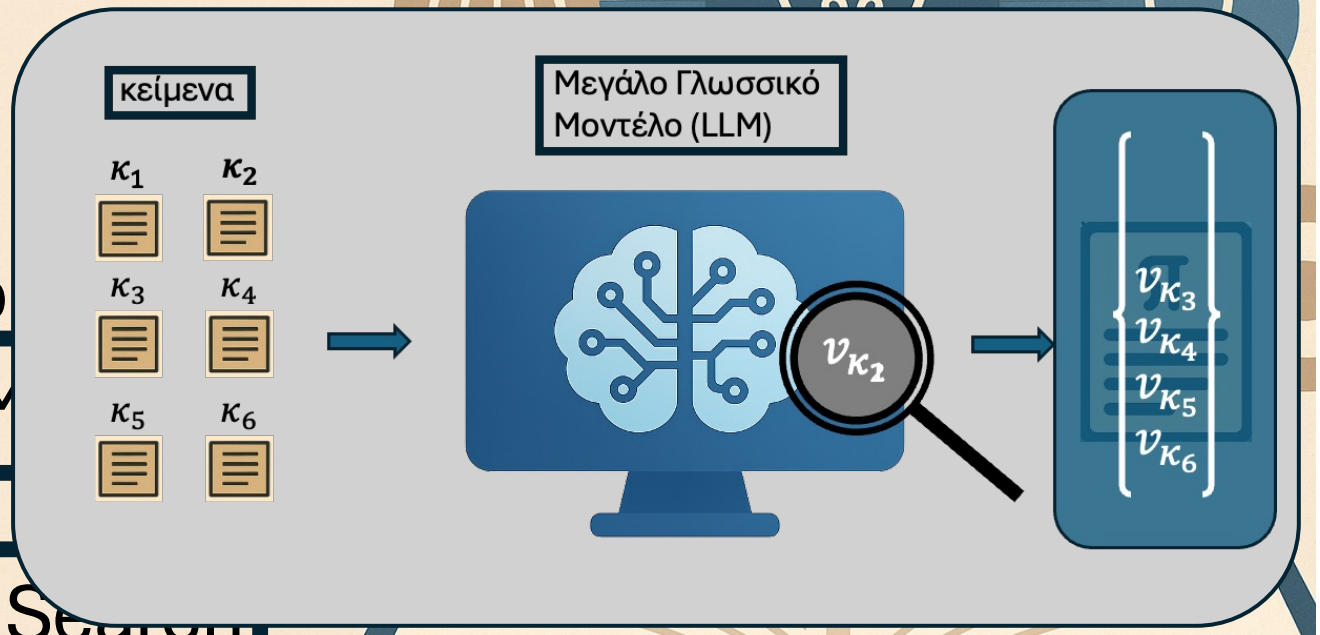

1. Bag of Wo
2. TF-IDF/BM
3. Seman

Πώς δημιουργούμε τη σημασιολογική ενσωμάτωση;